

密级★保密期限：____（涉密论文须标注）

浙江理工大学

Zhejiang Sci-Tech University

硕士学位论文

Master's Thesis



中文论文题目：____ 基于机器视觉的农业导航系统

英文论文题目：____ **The agricultural navigation system based on machine vision**

学科专业：____ 计算机科学与技术

作者姓名：____ 汪博

指导教师：____ 桂江生

递交日期：____ 2015 年 4 月 15 日

浙江理工大学学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得浙江理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：江博

签字日期：2016年6月12日

学位论文版权使用授权书

本学位论文作者完全了解浙江理工大学有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权浙江理工大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：江博

签字日期：2016年6月12日

导师签名：林

签字日期：2016年6月12日

摘要

随着机器视觉技术的不断发展,农业机器人使用视觉导航技术进行作业已经成为现代智能农业机械一个重要研究方向,在自动喷药施肥、收割作业、耕种除草、病虫害检测等方面有着广泛的应用。

本文根据目前农业领域机器视觉技术发展现状,在总结国内外相关研究成果的基础上,设计并开发了一套基于机器视觉的农业导航系统,本文的主要研究工作和成果如下:

(1)针对农业环境的多变性和复杂性,为了保证在各种环境中分割的成功率,采用了基于局部特征的层级分割结构进行图像分割,由于层级分割结构计算过程复杂,往往需要耗费大量的时间和内存,因此采用了基于离散-连续的最优梯度方向信号预测算法,相较于不使用预测算法,可以保证在成功分割的前提下减少40%的计算时间和10%的内存使用。

(2)由于目前农作物种植大多为条播法,但在导航线提取时往往只用到两条作物行,因此许多研究中在图像处理过程中创建感兴趣区域(ROI)用于简化计算。针对目前研究中ROI多为人工创建的现状,提出自动ROI的思想。跟人工创建ROI相比,自动ROI可以根据条件和参数变化进行自我调整,如作物种类、拍摄角度等,不再只局限于某一特定作物或场景,增强了系统的鲁棒性。

(3)针对杂草存在对导航线提取精度的影响问题,使用了机器学习进行杂草识别,一共使用了三种分类器进行实验,分别是人工神经网络,支持向量机和随机森林。实验结果表明,三种分类器都可以识别出杂草,其中随机森林的效果最佳,对作物的识别率为93.8%,杂草的识别率为91.1%,所以选择随机森林作为杂草识别的分类器。

(4)对于杂草识别后的作物行识别问题,由于已经创建了合适的ROI,并且排除了杂草的影响,此时使用横条法加线性回归的组合算法更加简单有效。通过对比实验证明,无论是在精度还是耗时组合算法均优于随机Hough变换,所以最终选择了横条法加线性回归的组合算法进行作物行检测。

(5)针对农田地形环境和实际需求,以韩伯电子技术研究所HBE-ROBOCAR型号机器人为移动平台,设计并开发了机器人控制系统。为了克服摄像存在的畸变问题,采用了OpenCV标定法进行了标定实验,最后在校内开展了仿真实验,

平均偏差角度为 2.02° 。

关键词：视觉导航；方向梯度估计；自动 ROI；杂草识别；作物行检测

ABSTRACT

With the continuous development of the machine vision technology, agricultural robot using visual navigation technology has become an important research direction of the modern intelligent agricultural machinery, and has a wide application in the automatic spraying fertilizer, harvesting, farming, weeding and pests detection and so on.

According to the current development of machine vision technology in agricultural field, and the relevant research results at home and abroad, this paper design and develop a set of agricultural navigation system based on machine vision. The detailed contents about research are as follows:

(1) In view of the variety and complexity of agricultural environment, in order to ensure the success rate of segmentation in various environments, this paper splits image based on the level of local feature. Due to the complicated calculation process of hierarchical segmentation structure and the consumption of time and memory, the prediction algorithm based on discrete and continuous optimal gradient direction signal, compared to those who did not use prediction algorithm, can reduce 40% of the computation time and 10% of memory use.

(2) Due to the crop drilling method, and only two crop rows used in navigation line extraction, creating region of interest (ROI) is used to simplify the computation in image processing. In view of the situation of the manual creation of ROI, this paper propose the automatic ROI. Compared with the manual creation of ROI, automatic ROI can be self adjusted according to changes in conditions, such as crop species, shooting angle and so on, which is no longer confined to a particular crop or scene.

(3) In view of weeds affecting the accuracy of the navigation line extraction, this paper identify weed by the machine learning, in the use of artificial neural network, support vector machine (SVM) and random forests. existing weeds in the farm, this paper use machine learning methods for weeds identification, including artificial neural network, support vector machine and random forest. The experimental results show that the three classifiers can identify weeds, and the effect of random forest is

the best, so random forest is selected as the classifier of weed identification.

(4) This paper have created the appropriate ROI and excludes the impact of the weed. In the view of crop recognition problem, horizontal and linear regression combination algorithm is simple and effective and ensure the efficiency and accuracy. Finally, this paper choose the horizontal and linear regression combination algorithm to detect the crop row, and conduct the experiment and analysis.

(5) According to the farmland terrain environment and the actual demand, the robot control system was designed and developed based on the HBE-ROBOCAR model of the Korean Electronic Technology Research Institute. In order to overcome the distortion of the camera, the OpenCV calibration method is used to calibrate the experiment. Finally, the simulation experiment is carried out in the school.

KEY WORDS: vision navigation; Gradient Orientation Estimation; auto ROI; weeds identification; crop rows identification

目录

摘要..... I

ABSTRACT..... III

目录..... V

第一章 绪论..... 1

1.1 研究的目的和意义..... 1

1.2 国内外的研究现状..... 2

1.2.1 国外研究现状..... 2

1.2.2 国内研究现状..... 4

1.3 章节安排..... 5

第二章 图像分割和自动 ROI..... 7

2.1 图像分割..... 7

2.1.1 引言..... 7

2.1.2 基于层级分割结构的图像分割..... 7

2.1.3 实验结果与分析..... 11

2.2 自动 ROI..... 14

2.2.1 自动 ROI 思想的提出..... 14

2.2.2 自动 ROI 创建原则..... 15

2.2.3 自动 ROI 创建算法..... 15

2.2.3 实验结果与分析..... 18

2.3 本章小结..... 19

第三章 杂草识别和作物行提取..... 20

3.1 杂草识别..... 20

3.1.1 引言..... 20

3.1.2 杂草识别方法介绍..... 20

3.1.3 实验结果与分析..... 27

3.2 作物行提取..... 30

3.2.1 作物行提取方法介绍..... 30

3.2.2 基于横条法加线性回归组合算法..... 33

3.2.3 实验结果与分析..... 34

3.3 本章小结..... 36

第四章 自动导航系统的设计与实现..... 38

4.1 硬件系统的设计与实现..... 38

4.1.1 硬件系统的搭建..... 38

4.1.2 摄像机的标定..... 41

4.2 软件系统的设计与实现..... 44

4.2.1 开发环境和工具..... 44

4.2.2 软件的开发与设计..... 44

4.3 仿真实验与结果分析..... 46

4.4 本章小结..... 48

第五章 结论与展望..... 49

5.1 结论..... 49

5.2 展望.....50

参考文献.....52

攻读学位期间的研究成果.....57

致谢.....58

第一章 绪论

1.1 研究的目的是和意义

进入 20 世纪后,科学技术得到了突飞猛进的发展,尤其由计算机技术为主导的第三次工业革命的爆发,彻底改变了传统农业生产方式,农业开始了从依靠人力到依靠大型机械的转型。从上世纪 50 年代开始,西方发达国家纷纷意识到农业机械化的重要性,并开始积极进行农业机械化改革,许多国家成功实现了农业机械化。相较于手耕时代,机械化的大量普及极大地提高农业生产的效率,是国家经济能够正常稳定发展的基础,但是目前的农业机械并不能解决农业生产中遇到的全部问题^[1]。进入 21 世纪,一方面要求农业机械能胜任更复杂更精细的任务,另一方面人们的环境意识也越来越强,老旧的农业机械越来越无法满足社会的需求,因此对农用机械也提出了更高的要求。这就需要机械、计算机等领域的专家研究开发性能更加优秀的机械。

俗话说:民以食为天。粮食对人类的重要性显而易见,中国作为世界上最大发展中国家同时又是农业大国,农业发展相对落后,依靠人力、畜力进行农业生产的现象在农村依然普遍存在。“三农”问题一直是中国政府最关心的问题之一,“三农”问题不解决,将会影响经济发展和社会稳定。中国有着悠久的农业历史,作物质量和种植水平已经趋于完善,科技投入已成为农业增长主要推动力,但是由于我国巨大的人口的压力和过度追求经济发展而不断恶化的生态环境,中国农业发展形式不容乐观。因此实施精准农业,广泛应用智能农业机械,以技术代替资源,提高资源利用率和生产效率,从而提高经济效益,将是 21 世纪农业发展的必然趋势^[2]。因此,研究开发高自动化,智能化的农业机械已经变得刻不容缓。

智能化农业机械在自动喷药施肥、收割作业、耕种除草、病虫害检测等方面都有广泛的应用^[3],许多应用都建立在自动导航的基础上的,所以自动导航是现代智能农业机械的一个重要组成部分,目前农业机械自动导航主要依靠两种方法,一种是 GPS(全球定位系统),复杂精确,研发费用高昂,往往应用于大型机械和大面积的田地;另一种是使用机器视觉导航^{[4][5]},机器视觉导航技术相对来说价格便宜,且从上世纪八十年代开始,传感器技术、人工智能、通讯技术等高新技术的得到了空前的发展,一些学者开始尝试利用机器视觉研发农业导航系统

目前已经有了很多成熟的技术。机器视觉导航技术是通过摄像机采集环境信息，并将这些信息传送到计算机进行图像处理，从而计算出导航信息反馈给机械，并能够在没有人工干预的情况下从出发点移动到目标位置。视觉导航具有实时性强，目标信息完整，成本低等优势受到各国研究人员的关注，并已经开始进行了相关研究，我国作物农业大国，视觉导航将会有广泛的应用前景。

1.2 国内外的研究现状

1.2.1 国外研究现状

上世纪七十年代末，美国麻省理工大学 D.Marr 教授首先提出了机器视觉的理论，并从三个不同层面理解机器视觉理论^[6]。随后的八十年代里，计算机技术经历了飞速发展，机器视觉也随之进入了高速发展期，并应用在包括农业在内的很多领域。

首先将机器视觉运用到农业领域的的是 Searcy^{[7][8]}等人，他们在 1985 年使用阈值分割和贝叶斯分类器成功实现图像分割，将棉花从土壤中分割出来，第二年他们运用 Hough 变换并成功提取出农田图像里的直线信息，并实现了农业机械的自主导航，Searcy 等人所提出的图像分割方法和 Hough 变换等方法被奉为经典，如今仍然在农业图像处理和导航领域被广泛运用。

1995 年 Gerrish^[9]等人基于 Case7110 型拖拉机，通过利用农作物和土壤在颜色上面的差异设计了在早期玉米秧苗地里的视觉导航实验，实验结果表明，拖拉机在 1.3m/s 速度取得的平均方差为 6cm，在 3.6m/s 速度下，平均方差为 12cm。

1999 年 Slaughter^{[10][11]}等针对西红柿种植通基于机器视觉导航设计了一套种植系统，当杂草较少时这套系统的精度可以达到 7mm，杂草较多时精度也可以达到 12mm，最高行驶速度可以达到 4.6m/s。

在 2002 年时瑞典的 Astrnad^[12]等在机械除草方面的研究取得了显著的成果，他们将杂草识别和导航作为两个独立的系统，从而可以消除光照变化给杂草识别带来的影响。因为使用了两个独立系统，所以引入人工光源去除光照影响变得十分方便。在杂草比较多的情况下，这种方法的导航的精度可以达到到了 2cm 左右。

2003 年 H.J. Olsen 和 H.T. Sogaard^[13]提出了一种不通过图像分割就可以识别

出作物行的算法,该算法提出了 2G-R-B 的灰度因子进行灰度化,还提出了横条法,即将灰度图像按一定的行进行分割,将横条的像素纵向相加得出特征点的位置,最后使用线性回归确定作物行位置。该方法纵向误差在 6-12mm 之间。

2004 年 M. Kise^{[14][15]}等研发了使用双目视觉的农业导航系统,该系统可以成功检测出作物垄的 3D 信息并用于提取导航信息,当系统以 3m/s 的速度前进,横向偏移误差为 5cm。

2007 年 Hannan 等同样使用了双目视觉技术,根据双目视觉成像模型计算出目标的位置信息,再通过农业图像处理的其他常用方法完成在不同光照强度下的目标定位,并且讨论了在有遮挡物时,如何检测目标的方法^[16]。

2008 年 Bakker 等人通过视角转化将原图像转化为鸟瞰图^[17],再将图像灰度化后分为三部分并进行累加,然后通过 Hough 变换提取作物行,再将鸟瞰图还原成功实现甜菜作物行的提取,实验结果表明该方法的误差为 6-11mm,处理一副图片的时间为 0.5-1.3s。

2012 年 J. Romeo 提出使用模糊聚类(FCM)进行图像分割^[18],J. Romeo 将图像的内容分为作物和背景(主要是土壤、石头等)两类,所以聚类数就是 2,在对图像每个像素的 R、G、B 三通道的值作为训练样本进行训练,最后得到作物的聚类中心 RGB 值为{137.80, 140.68, 106.07},背景的聚类中心 RGB 值为{188.49, 177.71, 153.53},于是得到分割阈值为 0.37,当像素 G 通道所占的比例大于 0.37,则认为是作物,否则认为是背景,从而完成分割。

2013 年 Guerrero 等人提出了一种较为准确的作物提取系统^[19],该系统主要有两大模块组成,一个是图像分割模块,一个是作物行提取模块,作物行提取不仅用于提取作物行,还通过 Theil-Sen 估计器用于修正作物行,实验结果表明该算法最多可以减少 84%的错误。

2015 年韩国科学技术院的 Keun Ha Choi 等人针对水稻田的形态学特点,设计与开发了一种基于形态特征的除草机器人^[20],通过使用 k-means 的方法将识别出的水稻根据作物行进行分类,再通过线性回归的方法识别出作物行,实验结果表明机器人的角度偏差小于 1°。

1.2.2 国内研究现状

在农业视觉导航这一领域,我国很多大学也在进行相关的研究,像南京农业大学、中国农业大学、南京林业大学、西安交通大学和浙江大学等已经取得了不错的成绩。但相比较与国外而言,由于我国进入这一领域较晚,现阶段仍然落后西方发达国家。

2001 和 2003 年南京农业大学的沈明霞和周俊分别从农业图像信息的提取作方面入手,进行了深入的研究^{[21][22]}。他们提出了一种新的算法,通过利用一种用小波变换的方法用来提取农作物图像边界,并对车辆导航所使用的传感器技术进行了详细的研究,他们把研究的重点放在转向控制算法,率先提出了两种控制算法,横向最优控制算法和横向预测模糊控制算法,最后以拖拉机为载体搭建了导航系统平台并进行了实验。

2004 年浙江大学的冯雷提出并设计一种较高精度的农用定位测试系统^[23],这套系统将廉价低精度 GPS 和传感器技术融合,建立了一种基于拖拉机—农具系统的转向动力学的模型,用于辅助拖拉机—牵引农具田间导航协调控制作业。

2006 年张方明参考生物机器人的概念设计了一套田间导航平台,并进行了基于立体视觉的田间环境 3D 重构方法和自动导航方法、车辆姿态估计算法的研究^[24]。室内测试的结果是:侧向偏差的 RMS 10.5mm,方差为 11.3 mm;偏向角的 RMS 为 1.1°,方差为 0.99°。为获得更加精密的姿态估计数据,张方明构造了多传感器信息融合的模型,并基于扩展 Kalman 滤波算法构建了姿态估计系统,实验表明侧向偏差的 RMS 为 8.7 mm,方差为 18.3 mm。

2006 和 2010 年赵颖^{[25][26]}对单目视觉导航的相关技术进行了深入研究,并对复杂农田场景和道路场景进行了描述和合理假设,通过对图像信息的处理和理解提取出导航路径,并根据导航路径信息对机器人的自定位技术进行了研究,最终求出机器人相对于导航路径的横向偏离和角度偏差。

2013 年胡炼等为实现智能化的株间机械除草装置自主避让作物并进入株间区域,提出了一种株间机械除草装置的作物识别与定位方法^[27]。利用 2G-R-B 方法将作物 RGB 彩色图像进行灰度化,再选用 Ostu 法二值化、连续腐蚀和连续膨胀等方法对图像进行了初步处理。根据行像素累加曲线和曲线的标准偏差扫描线获得作物行区域信息,以作物行区域为处理对象,利用列像素累加曲线、曲线标

准偏差和正弦波曲线拟合识别出作物,并结合二值图像中绿色植物连通域的质心获得作物位置信息。试验结果表明,该方法可以正确识别出作物并提供准确的定位信息,能适应不同天气状况、不同种类的作物,棉苗正确识别率为 95.8%,生菜苗正确识别率为 100%,该方法为株间机械除草装置避苗和除草自动控制提供了基本条件。

2014 年孟庆宽针对基于机器视觉的农业导航机器人在图像处理时易受光照变化影响和常规导航线检测算法实时性、稳健性不高等问题,提出了 YCrCg 颜色模型^[28],选择该颜色模型中与光照无关的 Cg 分量进行后续图像处理,采用基于二维直方图的模糊 C 均值聚类法(FCM)进行图像分割,并根据图像中作物行的特点,提出了基于直线扫描的作物行直线检测算法。该算法将图像底边和顶边像素点作为直线的两个端点,通过移动上下端点位置产生不同斜率直线,选择包含目标点最多的直线作为作物行中心线。实验表明,不同光照下基于 YCrCg 颜色模型的图像分割可以有效地识别出作物行,处理一幅 640pixel×480pixel 图片耗时约为 16.5ms,直线扫描算法能快速准确的检测出导航线,与最小二乘法、Hough 变换等算法相比具有速度快、抗干扰性强等优点。

2015 年中国农业大学的张漫设计和开发了基于机器视觉的农业导航系统^[29],该系统由彩色摄像机、工业计算机、侧向位移控制器、GPS 接收装置和一个液压系统组成,提出了基于线性扫描作物行识别算法,通过模糊控制指导系统行动,在 0.6m/s, 0.6m/s 和 0.6m/s 三种速度下在玉米地进行实验,三种速度下的最大误差分别为 4.5cm, 5.5cm 和 6.8cm。

1.3 章节安排

本论文共分为五章,其章节安排如下:

第一章:绪论。阐述了本文的研究目的和意义,介绍了目前国内外关于视觉导航的研究现状,最后介绍了本文的研究内容和结构安排。

第二章:图像分割和自动 ROI。主要介绍了基于离散-连续的梯度方向的图像分割方法,并进行了实验和分析;提出自动 ROI 的思想并给出了解决方案和实验。

第三章:导航路径的提取。使用神经网络、SVM 和随机森林三种方法进行

杂草识别，进行了实验并对结果进行对比；介绍和实现了基于横条法的作物行识别算法，通过对比最终选择横条法加线性回归的组合算法。

第四章：系统是设计和实现。介绍了实验过程中用到的相关技术和实验设备，设计并进行了模拟实验。

第五章：结论和展望。总结了本文的主要研究内容，指出本文研究有待提高和改进的方面，并阐述下一步的研究工作。

第二章 图像分割和自动 ROI

2.1 图像分割

2.1.1 引言

图像分割是把原始图像按照一定规则分割成两个或若干个不同区域，并从中提取出目标区域的过程，图像分割是图像处理的关键步骤之一。目前图像分割方法主要分为以下几类：基于阈值的分割方法、基于边缘的分割方法、基于区域的分割方法以及基于特定理论的分割方法等。在农业图像处理领域，由于农业环境很容易受到时间天气的影响，具有不确定性，所以一般的分割方法未必适用于农业场景。为了克服农业环境的影响，学者们纷纷提出了许多适合农业场景的分割方法，其中应用最广的方法有超绿法^[30]和模糊聚类法^[18]。

这些方法在正常情况下已经可以得到较好的分割结果，但相较于工业图像处理在室内的流水线作业，农业图像处理由于多在户外，情况会更加复杂，会面临许多如天气、光照、作物自身的各种不同情况，现有的方法无法在各种情况下均较好的完成分割。近些年机器学习技术得到了飞速发展，机器学习自我学习解决复杂问题的能力和取得的成就不菲，因此我们将机器学习引入农业图像分割用于克服上述问题。本文采用基于局部特征的层级分割结构，基于离散-连续的最优梯度方向信号预测算法，并选择随机森林作为训练分类器，达到同时保证精度和效率的目的^[31]。

2.1.2 基于层级分割结构的图像分割

图像分割的目标是将一副图像划分为几个有意义的区域，根据近年的发展趋势，通过层级分割结构进行图像分割主要分为两步，(1)超像素分割，将图像划分为许多较小区域（通常是上百个），同一物体允许被划分为更多更小区域，但划分的区域要求都不能跨越目标边界；(2)将这些超像素按一定规则合并，得到若干个区域，作为之后分割的依据。

目前已经有许多学者提出通过使用层次结构进行图像分割，并且已经取得了不错的效果^{[32][33][34]}。这类方法为了完成分割需要在低级层次先进行准确的超像

素分割，再在高级层次将相似内容进行合并，从而得到若干区域。而这一类方法中要数 UCM^[34]的效果最好，在许多应用中已经证明可以提高图像分割的效果。

为了克服其他方法对户外复杂情况的弱适应性，本文使用了基于局部特征的层级分割结构进行分割，并通过基于离散-连续的梯度方向估计进行优化，从而保证在不牺牲准确度的基础上提高处理速度。该方法的核心思想是使用一个离散-连续的学习方法对各种情况的图片的局部中级区域描述符进行学习，从而可以预测各种情况的图片的每一个像素点的局部梯度。

该方法主要包括训练和分割两个步骤，(1)首先训练模型，包括彩色图像和标准图像分割训练集；(2)模型训练完毕后，就可以预测每一个像素点方向梯度，这些信息将用来进行方向分水岭分割（oriented watershed transform），得到的层级分割结构就是我们所需要分割结果。

2.1.2.1 训练

假设现在有 N 副彩色图像：

$$I = \{I_1, I_2, \dots, I_N\} \quad 2-(1)$$

和对应的标准分割图像：

$$S = \{S_1^1, S_1^2, \dots, S_1^{k_1}, S_2^1, \dots, S_2^{k_2}, \dots, S_N^{k_n}\} \quad 2-(2)$$

其中每一幅图片 I_i 都会被分割为 k_i 个的分割区域 S_i^j ，每一个标准图像分割结果都可以用二值图像 B_i^j 表示，二值图像 B_i^j 表示的是 k_i 个区域的轮廓。

训练的目的是为了用训练结果预测方向梯度信号 $\nabla = \{\nabla_1, \nabla_2, \dots, \nabla_C\}$ ，其中 C 是方向的离散化水平，然后利用预测结果用来推导出层级分割结构。通过学习一个回归量是预测方向梯度最直接的方式，学习完毕的回归量可以将局部区域描述符的信息映射到 C 个不同的梯度方向中，为了在得到准确的结果的前提下加快训练速度，减少内存使用，我们在学习过程中使用了离散-连续的推导过程：首先进行分类器训练，将每一个局部区域分配到正确的边缘区域原型 $P = \{P_1, P_2, \dots, P_P\}$ 或者背景类 P_{P+1} 中的某一类中去。被分配到同一个类 P_i 的所有局部区域将用来定义一个预测方程 R_i ， $i=1, \dots, P$ （背景预测为零级）来获得连续方向梯度。

训练过程总共分为三步(1)边缘区域原型识别；(2)原型分类器训练；(3)方向梯度回归。

(1)边缘区域原型识别

首先使用标准 K 均值对中级边缘区域原型进行分类。从训练集中的二值图像 B_i^j 中随机选择一些大小都为 $S \times S$ 的正边缘区域 p_i ，正样本的意思就是所选的区域的中心像素恰好处于分割边界上，也就是说 B_i^j 的中心点的二值大小为 1。

为了保证能够处理局部区域边缘的微小变化，我们使用基于方向梯度直方图的 Daisy 描述符^[35]并用 K 均值聚类进行分类，从而获得了一系列具有代表性的边缘区域原型 $P = \{P_1, P_2, \dots, P_3\}$ ，每一个正边缘区域对应唯一一个边缘区域原型。

(2)原型分类器训练

一旦我们获得了 P 原型，我们将开始训练一个独立的中级区域分类器。

$$f: R^D \rightarrow L \quad 2-(3)$$

这个公式可以为 D 维的向量 x ，即中级区域描述符，从事先定义的标签集 $L = \{l_1, l_2, \dots, l_{p+1}\}$ 中分配一个标签，我们一共定义了 $P+1$ 个标签，包括 P 个原型和一个背景。

为了定义训练样本，我们将所有的区域分配到对应的聚类中，这些聚类是通过正边缘区域（标签 $\{l_1, l_2, \dots, l_{p+1}\}$ ）进行 K 均值得到，对于背景我们随机从训练集中（标签为 l_{p+1} ）取样非边缘区域（中心像素值为 0）。使用了 Lim JJ^[36]提出的特征作为输入，Lim JJ 所提出的特征使用了整体图像结构，在分割方法中使用了颜色通道，梯度幅值，量化的梯度通道，自相似特征等。

试验中我们选择随机森林作为分类器，因为随机森林自身概率性和高效性的特点所以天生具有处理多类别问题的能力，在一些机器视觉应用中的表现优于其它方法。我们按照^[37]中介绍的方法构建随机森林分类器，当随机森林构建完成后，我们就可以预测未处理的测试样本。

(3)方向梯度回归

我们为每一个边缘区域原型聚类定义了一个 prototype-specific 预测方程。

$$r^l: R^D \rightarrow R^C \quad 2-(4)$$

其中 l 是一个原型聚类的索引, D 是特征向量的维数, C 是梯度方向的离散化数量。通过方程 r^l , 我们能够预测每个中级区域的方向梯度信号 $\nabla = \{\nabla_1, \nabla_2, \dots, \nabla_C\}$, 其中核心思想就是使用梯度识别器进行^[38]。因此我们使用 gPb 算子识别器处理训练数据集 I , 通过从正中级训练区域组成的集合中随机选择样本, 我们考虑该区域的中心像素的 C 个方向梯度作为训练集。

因为之前已经为每一个区域分配了一个标签, 所以需要为每一个非背景类定义一个回归方程 r^l , 其中背景类的梯度大小始终为 0。每一个原型聚类通过分配到这个聚类里的样本的平均梯度方向的平均值得到 $\bar{\nabla}^l = \{\bar{\nabla}_1^l, \bar{\nabla}_2^l, \dots, \bar{\nabla}_C^l\}$ 。为了预测我们使用概率赋值 $p(l|x)$ 去衡量每一个聚类的相关的平均梯度反馈值, 从而可以为每个测试图片的中级区域预测局部方向梯度。

2.1.2.2 分割

在分类器 f 和每个原型对应的预测方程 r^l 训练结束之后, 就可以开始预测图像的局部梯度方向密度。首先计算局部特性, 每个像素都会产生一个 D 维的向量 $x \in R^D$, 向量 x 会被送入通用分类器 f , 用于返回的特定类的后验概率 $p(l_i|x)$ 。这时我们使用一个加权组合的平均原型梯度方向公式进行预测:

$$\nabla = p(l_i|x)\bar{\nabla}^l \quad 2-(5)$$

这个分类过程能够预测一个中级区域的中心像素有边界的可能性 e :

$$e = \sum_{i=1 \dots P} p(l_i|x) = 1 - p(l_{P+1}|x) \quad 2-(6)$$

其中标签 $P+1$ 表示背景类, 利用边缘概率 e 进行再加权得到每个像素的梯度方向信号。

最后一步和 Ultrametric Contour Map (UCM)^[34]算法相同, 通过使用预测得到的局部梯度方向并利用方向分水岭算法得到一个过度分割的图像(得到的分割结果是我们认为的层级结构最高层级, 即分割层次的叶节点), 最后使用了贪婪合并并进行合并。

2.1.3 实验结果与分析

为了测试分割结果，我们准备了 105 张彩色图像，其中 45 作为训练集，20 张作为验证集，40 张作为测试集。我们用上面介绍的方法训练局部方向梯度预测器，用验证集调整参数，最后调整区域的大小为 $S=31$ ，特征向量为 17654 维， $P=2$ 中级原型区域，及所有训练目标只分为背景和作物两类， $C=8$ ，及 8 个梯度方向。学习过程使用的是 Piotr Dollar^[39]提供的随机森林框架，实验结果如图 2.1 所示。






图 2.1 实验结果(a)原图(b)分割结果

传统农业图像分割算法，如超绿法、模糊聚类在正常情况下可以很好的完成作物分割任务，但面对复杂的情况时往往效果不是很理想。为了测试本文所采用的方法对不同环境的适应性，我们在不同天气和时间进行图片采集，如图 2.2 所示，一共列举了晴天中午、晴天傍晚、阴天中午、阴天傍晚、雨天，阴影和雾天七种情况，并与超绿法和模糊聚类两种算法进行对比实验。




(a)




(b)




(c)



(d)



(e)



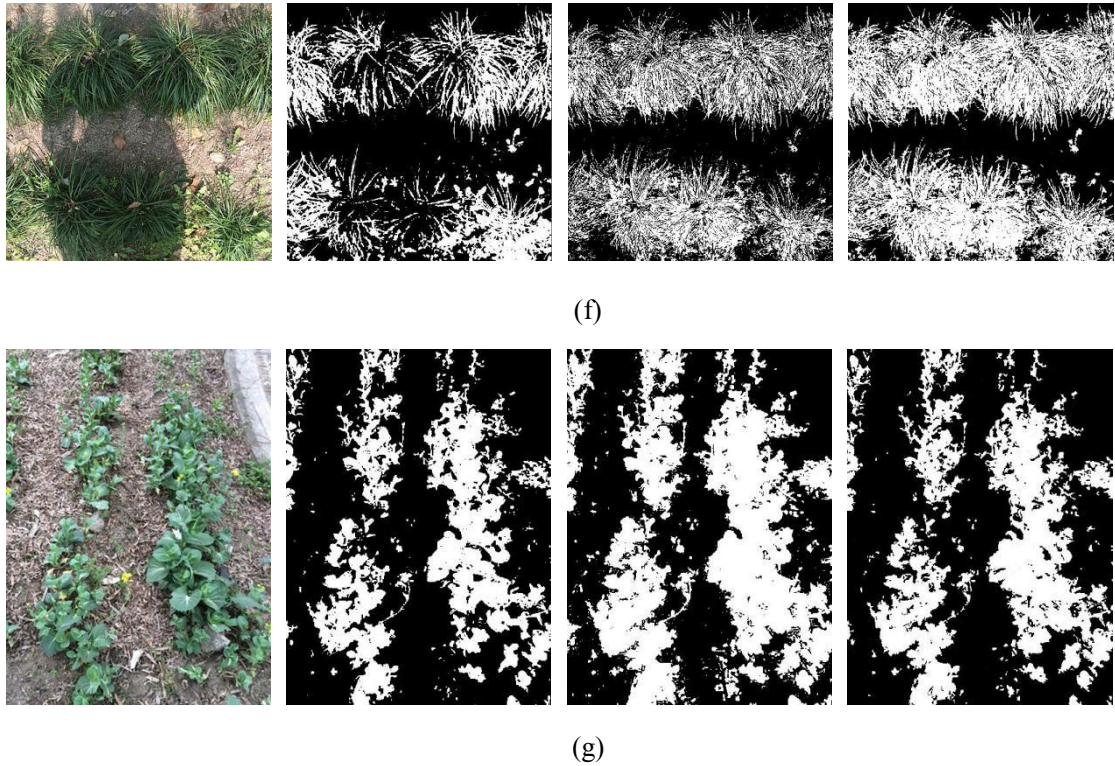


图 2.2 不同情况下三种分割方法的实验结果(a)晴天中午(b)晴天傍晚(c)阴天中午(d)阴天傍晚(e)雨天(f)有阴影的情况(g)有雾的情况（从左到右分别是原图，超绿法，模糊聚类，本文方法）

通过比较图 2.2 的实验结果，我们可以发现，在正常天气情况下，三种方法的都可以很好的完成分割；由于超绿法需要先通过 2G-R-B 算子先将彩色图像转化为灰度图，再通过 Otsu 进行二值化，当光照强度较弱的阴雨天，或是出现阴影时，由于整体亮度偏低，会导致 2G-R-B 的结果偏小，灰度图的灰度值过度集中在一个较小的区域，造成分割困难；模糊聚类是通过 $\frac{G}{R+G+B}$ 的比值进行聚类，将所有像素点分到两个类中，从而将原图进行二值化，因此对弱光和阴影适应性较强，但由于只通过 G 通道所占比例进行聚类会出现许多错误聚类，导致分割图片出现大量黑白噪点，会对后续处理造成困难；而本算法对颜色通道，梯度幅值，量化的梯度通道，自相似特征等进行全面的考虑，并通过训练可以准确的预测出像素的方向梯度，所以并不会出现上述问题。实验结果证明，本算法相较于超绿法和模糊聚类具有更强的适应性。

2.2 自动 ROI

2.2.1 自动 ROI 思想的提出

在确定导航线时，往往只用到移动平台两侧的两条作物行，所以无论是图像分割还是导航线提取，一幅农业图像中有许多信息实际上是可以忽略不处理的。如果每次都对整幅图像进行处理，一是会增加图像处理的计算量，不利于实时性；二是需要将不同作物行都分开，加大了后续处理的复杂度。

为了应对这种情况，创建合适的 ROI 显得尤为重要。相反，如果创建 ROI 的位置及大小不合适，反而会影响正确的实验结果。以图 2.3 为例：在图 2.3(a) 和(b)中，作物行间隔基本相同，为了保证所创建的 ROI 中保留中间两条作物行，于是在两条作物行之间选择 ROI 的左侧起点和右侧终点，并设置 ROI 的宽为原图的一半，起点距左侧宽度的 $1/4$ ；为了保证有足够多的作物信息，而又不会包含其他作物行，高度选择为原图高度的一半。最终结果如下：



图 2.3 人工设置 ROI 示意图

图 2.3 中红色矩阵表示的区域就是按照上述方法创建的 ROI，这是比较理想的状态，这时 ROI 中只存在两条作物行，因此在后续的处理中位置标志点的归属就非常容易判断，为后续的图像处理提供了极大的便利。

然而现实中，并不会每次都像图 2.3 中那样出现比较完美的情况。1.在导航过程中，ROI 可能会根据情况不断调节，而我们并不能在导航过程中不断重新设置 ROI；2.根据作物生长阶段，拍摄角度等都会影响作物行的分布，导致需要重新设置 ROI。所以在实际操作中，人工标定 ROI 并不实用。这时，自然而然就想到是否可以让机器自己寻找正确的 ROI。

2.2.2 自动 ROI 创建原则

为了实现自动 ROI，首先需要弄确认设置 ROI 的原则，及如何设置 ROI，在经过大量的实验和经验总结后，总结出农业视觉导航时 ROI 创建三条主要原则：

- (1) 要保证 ROI 的信息是当前导航所需要的，以及信息的实时性，这主要由 ROI 所处的纵坐标决定；
- (2) 要保证 ROI 只包含两条作物行，且这两条作物行是提取导航线所必须的，同时应该尽量避免包含其他作物行，以防对导航造成干扰，这主要由 ROI 的横坐标决定；
- (3) 要保证 ROI 有足够的作物信息，这样得到的结果才会更精确，这主要由 ROI 的高和宽决定；

2.2.3 自动 ROI 创建算法

根据以上三个原则，我们设计了自动 ROI 算法。为了保证 ROI 里的信息是实时所需的，ROI 的位置应该尽可能靠近图像下侧，因为图像下侧为导航系统所在的位置。所以无论 ROI 其他条件怎么变，ROI 的下侧应该与原图像的下侧保持重合。

要保证 ROI 有足够的作物信息，需要保证 ROI 有足够的高度，在实验发现，这个数值一般不需要改变，可以用一个固定值。推荐值在原图高的 $1/3-2/3$ 之间，本实验采用的值为原图高的 $1/2$ 。只有当通过左右两侧调节无法将其他行排除在外时，才需要改变该值。一般这种情况出现的概率较低。

要保证 ROI 只包含两条作物行，这是计算 ROI 的关键，为此设计自动 ROI 算法：

(1) 判断作物行的位置

根据 2.1 我们可以得到分割后的二值图像，其中白色像素代表作物部分，黑色像素表示背景。首先计算每一列的白色像素出现次数 $s(i)$ 。从左往右遍历列值，当 $s(i)$ 到达局部最大值时，说明进入作物区域。这时均值 μ 和阈值 d 被创建用来判断是否找到作物行，其中 μ 用来判断是否进入作物区域， μ 表示平均每列像素个数的均值，大小与作物像素的总数有关，当 $s(i)$ 大于 μ 时，说明进入作物行；当 $s(i)$

小于 μ 时, 说明离开作物行。阈值 d 用来判断该区域是否为作物行, 如果通过 μ 得到的作物行区域宽度小于 d , 则认为是杂草或落叶等噪点, 需要排除。于是, 我们便可以粗略的判断每条作物行的横坐标, 如图 2.7 所示, 识别出的作物行的横坐标用绿色竖直线表示。

(2)创建或调整 ROI

从图像中心线往两侧遍历, 最先找到的两条作物行直线为 $L_{外}$ 、 $R_{外}$ 、 $L_{内}$ 和 $R_{内}$, 对应的位置如图 2.8 所示, 在导航大部分时间中, ROI 里往往会不存在 $L_{外}$ 和 $R_{外}$ 两条竖直线, 这时则用 ROI 左右两边代替。根据总结的第二条原则, ROI 里应该只包含两条作物行, 这时会出现两种情况, 情况 1: 如果为第一次创建 ROI, 这时创建的 ROI 左侧边所在的横坐标应该为 $L_{外}$ 和 $L_{内}$ 的中点, 左侧边所在的横坐标应该为 $R_{外}$ 和 $R_{内}$ 的中点; 情况 2: 如果不是第一次创建 ROI, 则需要根据第一步所得到作物行的位置和上一次所得到的 ROI 的位置为前提, 对 ROI 进行了调整。

ROI 左右两侧边的变化趋势分别由下面的式子决定:

左侧:

$$E_{L_{内}} = -a(x_{L_{内}} - x_{L_0}) \quad 2-(7)$$

$$E_{L_{外}} = b(x_{L_{外}} - x_{L_0}) \quad 2-(8)$$

$$E_L = c(E_{L_{内}} + E_{L_{外}}) \quad 2-(9)$$

右侧:

$$E_{R_{内}} = a(x_{R_{内}} - x_{R_0}) \quad 2-(10)$$

$$E_{R_{外}} = b(x_{R_{外}} - x_{R_0}) \quad 2-(11)$$

$$E_R = c(E_{R_{内}} + E_{R_{外}}) \quad 2-(12)$$

在式 2-(7)到 2-(12)中, a , b , c 为三个经验系数并且 $a>b$, x_{L_0} 、 $x_{L_{内}}$ 、 $x_{L_{外}}$ 分别代表图像左侧三条竖直线 L_0 、 $L_{内}$ 、 $L_{外}$ 的横坐标。 x_{R_0} 、 $x_{R_{内}}$ 、 $x_{R_{外}}$ 分别代表 R_0 、 $R_{内}$ 、 $R_{外}$ 的横坐标。 $E_{L_{内}}$ 和 $E_{L_{外}}$ 分别表示 $L_{内}$ 、 $L_{外}$ 对 L_0 的影响程度, 它们决定了 L_0 如何变化。当 $E_L>0$, L_0 需要左移; 当 $E_L<0$ 时, L_0 需要右移。

在式 2-(7)到 2-(11)里 x_{R_0} 、 $x_{R_{内}}$ 、 $x_{R_{外}}$ 分别代表图像右侧侧三条竖直线 R_0 、 $R_{内}$ 、

$R_{\text{外}}$ 的横坐标, 其他变量含义与式 2-(10)到 2-(12)相同。



图 2.4 作物行原图



图 2.5 作物行二值图像



图 2.6 二值图像的 $s(i)$ 统计图



图 2.7 计算所得的作物行所在位置（从左往右四条绿色竖直线分别为 $L_{外}$ 、 $L_{内}$ 、 $R_{外}$ 和 $R_{内}$ ）




图 2.8 计算得到的 ROI 位置与大小

2.2.3 实验结果与分析

在实际试验中，自动 ROI 会出现四种情况，分别是：

1. $L_0 > L_{内}$ ， $R_0 < R_{内}$ ，ROI 偏小
2. $L_0 > L_{内}$ ， $R_0 > R_{内}$ ，ROI 偏右
3. $L_0 < L_{内}$ ， $R_0 < R_{内}$ ，ROI 偏左
4. $L_0 < L_{内}$ ， $R_0 > R_{内}$ ，ROI 偏大

图 2.9 和图 2.10 表示的分别是第 1、4 两种情况。由于通过 2.2.2 已经可以确认作物行的大概位置，当 ROI 偏小时，根据式 2-(18)可知， $E_{L_{内}} > 0$ ， $E_{L_{外}} > 0$ ， $E_{R_{内}} > 0$ ， $E_{R_{外}} > 0$ ，这时 $L_{内}$ 、 $L_{外}$ 、 $R_{内}$ 、 $R_{外}$ 对 ROI 起的扩大作用，会使 ROI 左右两侧均往外移动，即 ROI 的宽度变大；当 ROI 偏大时 $E_{L_{内}} < 0$ ， $E_{L_{外}} > 0$ ， $E_{R_{内}} < 0$ ， $E_{R_{外}} > 0$ ，这时 $L_{内}$ 和 $R_{内}$ 起的是起缩小作用， $L_{外}$ 和 $R_{外}$ 起的是扩大作用，这时 ROI 的变化要根据 $E_{L_{内}}$ 、 $E_{L_{外}}$ 、 $E_{R_{内}}$ 、 $E_{R_{外}}$ 的大小决定。换言之就是如果靠近 $L_{外}$ 或 $R_{外}$ ，ROI 宽度会变小，靠近 $L_{内}$ 和 $R_{内}$ ，ROI 宽度会变大。




图 2.9 情况 1 ROI 变化结果




图 2.10 情况 4 ROI 变化结果

2.3 本章小结

本章首先介绍了基于离散-连续梯度方向的图像分割方法，随后将该方法和传统超绿法进行对比，对比实验选择了晴天中午、晴天傍晚、阴天中午、阴天傍晚、雨天，阴影和雾天七种条件下进行实验，实验结果表明该方法相较于传统农业图像识别方法如超绿法，本方法具有鲁棒性的优势；然后介绍了 ROI 在农业视觉中的必要性，并总结了 ROI 的创建原则并设计了自动 ROI 的创建方案，最后进行实验进行验证。

第三章 杂草识别和作物行提取

3.1 杂草识别

3.1.1 引言

通过第二章我们可以得到 ROI 的二值图像，在农业视觉导航里，杂草问题一直是农业视觉导航里的重要处理过程。农业图像或多或少会存在一定量的杂草，杂草的出现位置与大小具有随机性，但由于杂草和作物行在光谱和形态上的相似性，杂草往往会被误认为是农作物被同时分割出来。如果杂草数量较少且靠近作物，可以通过后期处理进行优化；如果杂草数量较多且远离作物，则可能会对后续的作物行识别造成巨大的影响，从而最终影响导航系统的准确性，导致整个实验的失败。在不能保证作业环境肯定没有杂草的情况下，我们在试验中加入了杂草识别这一环节。

3.1.2 杂草识别方法介绍

近年来随着机器学习技术的快速发展，各国学者开始使用机器学习进行杂草识别，常用的方法有支持向量机和神经网络^{[40][41]}，但是这两种方法都存在各自的弊端，如神经网络会出现过度拟合的情况，SVM 的性能取决于选择的核函数，随机森林是一种有效的机器学习方法，有很多突出的优点。本文使用这三种方法进行实验，寻找最好的方法。

3.1.2.1 神经网络

在 40 年代初人工神经网络被首次提出，但直到 Mitra 在 1995 年将人工神经网络与模糊逻辑理论、生物细胞学和概率论相结合提出了模糊神经网络才引起了各国学者的广泛关注，从那之后神经网络的研究才开始取得了突破性进展，如今神经网络已经应用到信号处理、计算机视觉，生物医学等众多领域中。

(1) 神经元模型

人工神经网络模型有许多种，如 MP 模型，感知器模型等，这些模型虽然各自存在差异，但都是由“神经元”组成，“神经元”是构成神经网络的最小单位，图 3.1 为一个简单的“神经元”模型。




图 3.1 “神经元”模型

在图 3.1 中 x_1, x_2, \dots, x_n 用于表示该“神经元”的输入信号，+1 表示运算单位，因此“神经元”的输出 $h_{w,b}(x)$ 可以用式 3-(1)表示：

$$h_{w,b}(x) = f(W^T x) = f\left(\sum_{i=1}^n W_i x_i + b\right) \quad 3-(1)$$

其中 f 表示一个激活函数，常见的激活函数有 sigmoid 函数和 tanh 函数等。

(2)神经网络模型

神经网络就是由多个“神经元”构成的网状结构，通常由输入层、隐藏层和输出层三部分组成。图 3.2 表示的是一个拥有三层结构的神经网络，左侧的 Layer L_1 称为输入层，其中“+1”的圆圈表示偏置节点，中间的一层 Layer L_2 称为隐藏层，因为在整个训练过程中我们并不知道它们的值，右侧的 Layer L_3 层称为输出层。所以图 3.2 是有 i 个输入单元， i 个隐藏单元和一个输出单元的三层结构的神经网络。

我们用 n_l 表示神经网络的层数，通常分为三层（图 3.2 中 $n_l=3$ ），用 L_i 表示该神经网络的第 i 层，显然 L_1 表示输入层， L_n 表示输出层，其它均表示隐藏层；我们用 $W_{ij}^{(l)}$ 表示神经网络第 l 层的第 j 单元与第 $l+1$ 层的第 i 单元之间的权重值； $b_i^{(l)}$ 表示第 $l+1$ 层第 i 单元的偏置项； S_l 表示第 l 层的节点数； $a_i^{(l)}$ 表示神经网络第 l 层第 i 单元的输出值。于是图 3.2 可以用下式计算得到输出结果：

$$a_1^{(2)} = f(W_{11}^{(1)}x_1 + W_{12}^{(1)}x_2 + \dots + W_{1n}^{(1)}x_n + b_1^{(1)}) \quad 3-(2)$$

$$a_2^{(2)} = f(W_{21}^{(1)}x_1 + W_{22}^{(1)}x_2 + \dots + W_{2n}^{(1)}x_n + b_2^{(1)}) \quad 3-(3)$$

.....

$$a_n^{(2)} = f(W_{n1}^{(1)}x_1 + W_{n2}^{(1)}x_2 + \dots + W_{nn}^{(1)}x_n + b_n^{(1)}) \quad 3-(4)$$

$$h_{w,b}(x) = a_1^{(3)} = f(W_{11}^{(2)}a_1^{(2)} + W_{12}^{(2)}a_2^{(2)} + W_{13}^{(2)}a_3^{(2)} + b_1^{(2)}) \quad 3-(5)$$

如果用 z_i^l 表示神经网络第 l 层第 i 单元输入的输入加权和，且

$$z_i^{(2)} = \sum_{j=1}^n W_{ij}^{(1)}x_j + b_i^{(1)}, \text{ 于是上式可以简化为 } a_i^l = f(z_i^{(l)}), \text{ 上述整个过程称为神经网络的前向传播。}$$




图 3.2 神经网络示意图

3.1.2.2 支持向量机

支持向量机 SVM 是一种分类模型，通过在特征空间上使不同类别的间隔最大的线性分类器。其学习策略是使间隔最大化，最终将分类问题转化为一个凸二次规划问题。支持向量机与传统学习方法相比在非线性、高维的模式识别和回归估计、小样本问题中有明显的优势，并且比较好的实现了结构风险最小化的思想，因此不存在局部最优的问题。

(1) 线性可分

当训练样本线性可分时，那么便存在一个最优分类面，最优分类面是指每一

个类与最优分类面距离最近的向量与最优分类面直接的距离最远的平面这个分类面可以通过学习寻优找到，假设分类面为：

$$w \cdot x + b = 0 \quad 3-(6)$$

其中 \cdot 表示点积， w 是 n 维向量， b 为偏移量，最优分类面可以约束成如下的优化问题：

$$\phi(w) = \frac{1}{2} \|w\|^2 = \frac{1}{2} (w \cdot w) \quad 3-(7)$$

满足约束条件： $y_i[(w \cdot x_i) + b] - 1 \geq 0, (i=1,2,\dots,n)$




图 3.3 线性可分情况示意图

当特征维数很大时，可以将这种二次规划问题转化为对偶问题，

$$\begin{aligned} \max W(a) &= \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i,j} a_i a_j y_i y_j (x_i \cdot x_j) \\ w^* &= \sum a_i y_i x_i \end{aligned} \quad 3-(8)$$

$$b^* = y_1 - w \cdot x_1$$

满足约束条件：，其中 $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 是 Lagrange 乘子， w^* 是最优分类面的

法向量 $\sum_{i=1}^n a_i y_i = 0, a_i \geq 0, i=1,2,\dots,n$ ， b^* 是最优分类面的偏移量，在对对偶问题求

解时，其解必须满足：

$$\alpha_i \{y_i(w \cdot x + b) - 1\} = 0, i=1,2,\dots,n \quad 3-(9)$$

由式 3-(9)可知，当样本的 $\alpha_i=0$ 时，不会对分类造成任何影响，只有当样本的 $\alpha_i>0$ 时才会对分类起作用，这些 $\alpha_i>0$ 的样本称之为支持向量，所以最后的分类函

数为:

$$f(x) = \text{sgn}\{(w^* \cdot x) + b^*\} = \text{sgn}\left\{\sum_{i=1}^n a_i^* y_i (x_i \cdot x) + b^*\right\} \quad 3-(10)$$

其中 $\text{sgn}()$ 为符号函数, b^* 是分类的阈值, 可以通过一个支持向量机求出, 或通过两类中任意一堆支持向量取中值求得。对于给定的位置样本 x , 只需计算 $\text{sgn}(w^* \cdot x) + b^*$, 便可判断 x 所属的分类。

(2) 线性不可分

现实问题中很多问题是线性不可分的, 如果还用最优分类面划分样本会产生较大的误差, 这时可以利用映射关系把分类问题从低维样本空间 x 转换到高维特征空间 H , 然后利用低维特征空间中的函数计算高维特征空间的内积。根据泛函相关理论, 如果核函数能够满足 Mercer 条件, 那么这个核函数就一定会在某一空间中的内积与之相对应。想要解决样本线性不可分的问题, 就需要选择合适的内积函数, 所以目标函数表示如下:

$$\max W(a) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i,j} a_i a_j y_i y_j K(x_i, x_j) \quad 3-(11)$$

对应的分类函数为:

$$f(x) = \sum_{i=1}^n y_i \alpha_i K(x \cdot x_i) + b^* \quad 3-(12)$$




图 3.4 非线性可分情况示意图

3.1.2.3 随机森林

随机森林 (Random Forest) 算法由 Leo Breiman 在 2001 年提出^[42], 随机森林是由一定数量的决策树按照某种准则组合生成。随机森林是一种有效的机器学习

习方法，有很多突出的优点：(1)能够有效地防止过度拟合现象，(2)可以快速处理高维数据，(3)当数据集中数据缺失严重时仍然能保持高精度等。随机森林在分类和回归中都有重要的应用，已经在药物发现、天文学、癌细胞分析、微阵列等^[43]多个领域取得了很好的效果。

(1)决策树理论

决策树是一个树状模型，主要由节点和有向边两部分组成，齐总节点分为根节点、内部节点和叶节点，根节点代表训练集或者测试数据集，每个内部节点代表一个属性，到达该节点的样本将按某种属性进行划分，所有的内部节点就将全体训练或测试数据集分割成若干个子集；最终叶节点用于表示这些训练或测试子集，从决策树的根节点到叶节点的每一条路径就对应一个分类过程。




图 3.5 二叉树示意图

现有的决策树生成算法有 ID3，C4.5，CART 等。这些决策树的生成原则均是递归分区，每个内部节点选择分类效果最好的属性来分裂该节点，直到全体训练或测试集被准确分类或所有属性都被用到为止。决策树的核心问题是分裂属性的选择，常见的有信息增益、信息增益比^[44]和 Gini 指标^[45]。根据决策树的节点的分枝个数，决策树可分为二叉树和多叉树。二叉树是最简单的决策树，我们给出了二叉树的示意图(如图 3.5)。

决策树是一种常用的分类算法，简单直观且速度快，但易于陷入过度拟合。

为了克服这些问题，随机森林算法被提出。

(2)随机森林的构造

随机森林是由很多决策树按照一定的准则组合而成的分类模型，每一棵决策树都依赖于一个随机向量和一个训练集。首先为第 k 棵决策树生成随机向量 θ_k ，且 θ_k 独立同分布与前面的随机向量， θ_k 决定了决策树的生成过程。然后利用随机抽样方法从原始训练样本 X 中为第 k 棵决策树生成了训练集 X_k 。利用了训练集 X_k 和随机向量 θ_k 生成第 k 棵决策树模型 $h(x, \theta_k)$ ，其中 x 为输入变量，通过 k 轮训练，得到 k 棵决策树 $h(x, \theta_k)$ ， $i=1,2,\dots,N$ 。最后通过投票的方法获取平均值的方式，将它们构成一个多分类模型系统，我们称这个模型为随机森林算法。若采用的是投票的方式来生成随机森林，则称为随机森林分类模型。

$$H(x) = \arg \max \sum_{i=1}^N I(h(x, \theta_i) = y) \quad 3-(13)$$

其中 $h(x, \theta_k)$ ， $i=1,2,\dots,N$ 是单颗决策树模型： y 表示输出变量， $I(\cdot)$ 为示性函数。

(3)随机森林的数学理论基础

与其它组合学习方法相比，当决策树数量增加时随机森林不会随之产生过度拟合，并且泛化误差最终会收敛于一个上界。假设现在有一组分类器 $h(x, \theta_k)$ ， $i=1,2,\dots,N$ 和一个训练集 X ，下面给出相关定义和定理。

定义 1：边际函数：

$$mg(x, y) = av_k I(h(x, \theta_k) = y) - \max_{j \neq y} av_k I(h(x, \theta_k) = j) \quad 3-(14)$$

其中 $I(\cdot)$ 表示示性函数， $av(\cdot)$ 表示平均值，在边际函数公式中，减数表示是对向量 x 正确分类 y 的得票数的平均值，被减数表示对向量 x 错误分类得票数的最大值，两者差值越大，表明组合分类器的性能越好，所以边际函数反映的其实是两者之间的差异程度。

定义 2：泛化误差：

$$PE^* = P_{x,y}(mg(x, y) < 0) \quad 3-(15)$$

泛化误差反映了算法对未在训练集中出现过的样本的分类能力，该值越小则表示算法的性能越好。

定理 1：当随机森林中决策树的数量很大时，树的结构和大数定律保证了随

机森林不会产生多度拟合：

$$\lim_{k \rightarrow \infty} PE^* = P_{x,y}(P_{\theta}(h(x, \theta) = y) - \max_{j \neq i} P_{\theta}(h(x, \theta) = j)) \quad 3-(16)$$

其中 $\theta = \{\theta_1, \theta_2, \dots, \theta_k\}$ ，从式 3-(16)可以看出随着决策树数量的增加，随机森林的泛化误差将收敛于一个上界，说明随机森林可以防止过度拟合的产生。

定理 2:泛化误差存在上界，由下面公式给出：

$$PE^* \leq \bar{\rho}(1-s^2)/s^2 \quad 3-(17)$$

其中 $\bar{\rho}$ 反映了决策树之间的相关性， s 反映了一棵决策树的分类能力，从式 3-(17)可以看出，如果决策树之间的相关性越小，那么一棵决策树的分类能力就越好，随机森林的泛化误差也就越低。

3.1.3 实验结果与分析

本文利用 Matlab 语言实验杂草识别算法，一共准备了 69 张包含杂草的图片，这些图片包含了天气，光照，杂草程度等各种情况。

在进行学习前需要提取训练特征，在杂草和作物识别中形状、轮廓、统计学特征等是最常用的一些特征^{[46][47]}。由于在杂草识别前已经完成图像分割，所以我们的样本集和测试集均为二值图像，这里显然无法使用颜色、纹理特征等一些特征值作为训练输入。为了保证杂草识别的精度，这里我们引入了特征点的概念^[48]，我们将特征点分两类，分别是杂草特征点和作物特征点。特征点的获得方法如下：

首先遍历所有的连通区域，做每个连通区域的外切矩形，如果外切矩形小于 $S \times S$ ，则为该连通区域内分配一个杂草特征点， S 的大小应该根据图片的大小做相应的调整；否则，使用一个大小为 $S \times S$ 矩形结构遍历这个外切矩形，通过矩形内白色像素的数目判断该矩形属于杂草还是作物，并分配相应的特征点，得到的特征点和杂草识别结果如图 3.6 所示。




图 3.6 特征点示意图(a)原图(b)二值图及特征点（绿点为作物特征点，红点为杂草特征点）
(c)识别结果（绿色代表作物，红色代表杂草）

因此，我们训练的基本单位为一个连通区域，并将连通区域和特征点的相关数据作为训练特征值，主要包括轮廓特征和特征点的统计学特征等。所有特征均在表 3.1 中列举出来。

表 3.1 特征描述

| 特征 (f_i) | 描述 |
|--------------|---------------------|
| f_1 | 周长（轮廓的长度） |
| f_2 | 面积（像素点的个数） |
| f_3 | 密度 (f_1/f_2) |
| f_4 | 单个矩阵里作物特征点的最大值 |
| f_5 | 单个矩阵里作物特征点的最小值 |
| f_6 | 单个矩阵里作物特征点的均值 |
| f_7 | 单个矩阵里杂草特征点的最大值 |
| f_8 | 单个矩阵里杂草特征点的最小值 |
| f_9 | 单个矩阵里杂草特征点的均值 |
| f_{10} | 单个矩阵里作物特征点与杂草特征点的比值 |

我们使用相同的样本和特征值对三种方法进行对比，实验结果如图 3.7 和表 3.2 所示，从图 3.7 和表 3.2 均可以看出，当样本数量较少时，SVM 识别效果最好，但是随着训练样本和训练时间的增加，随机森林体现出优势。由此我们可以得出结论，在杂草识别时随机森林效果最好，支持向量机次之，神经网络最差，所以最后我们选择了随机森林作为杂草识别的分类器。

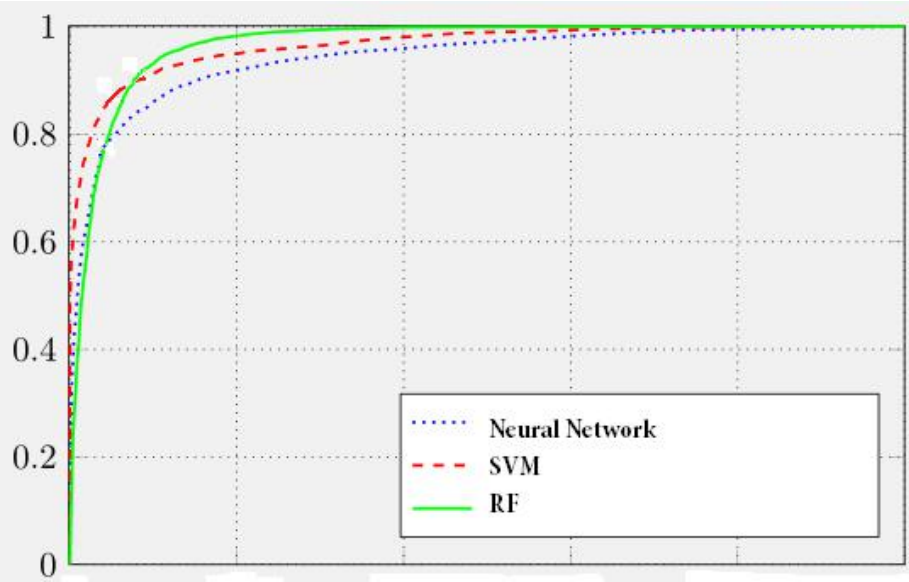


图 3.7 三种方法正确率

表 3.2 三种学习方法准确度对比

| | 作物 | | | 杂草 | | |
|------------------------|-------|------|-------|------|------|-------|
| | 正确个数 | 错误个数 | 正确率 | 正确个数 | 错误个数 | 正确率 |
| 神经网络 (Neural Network) | 8893 | 2019 | 81.5% | 1018 | 192 | 83.9% |
| 支持向量机 (SVM) | 9613 | 1299 | 88.1% | 1036 | 177 | 85.4% |
| 随机森林 (RF) | 10235 | 677 | 93.8% | 1105 | 108 | 91.1% |

3.2 作物行提取

3.2.1 作物行提取方法介绍

为了实现自动导航系统，最后也是最重要的一步就是提取作物行，提取作物行后，求出两条作物行的中线就是导航系统的导航路径，之前的所有工作均是为成功提取作物而做的准备工作。由于现代农业播种普遍采用条播法，这就使得作物行呈若干条并行的直线，所以作物行识别问题也就转化为作物行识别问题。常用的直线检测方法有 Hough 变换和线性回归两种方法。

3.2.1.1 Hough 变换

霍夫变换 (Hough Transform)是图像处理时常用的形状检测技术，在农业图像中经常被用来识别作物行。Paul Hough^[49]在 1962 年首次提出霍夫变换，随后 Richard Duda 和 Peter Hart 在 1972 对其进行了推广^[50]，最开始霍夫变换是用来检测直线，后来拓展到可以检测任意形状，只要能够写出该形状的方程。

在直线检测中，霍夫变换需要使用到两个坐标系，并将一个坐标系之中具有相同形状的直线映射到另一个坐标空间的点上，通过统计第二个坐标系上点的峰值投票选出最有可能的直线。

假设在 xoy 坐标系中有一条用斜截式表示的直线方程 $y_i = ax_i + b$ 和一个点 (x_i, y_i) ，经过点 (x_i, y_i) 的直线可以有无数条，且当 a 和 b 的值发生变化时，仍然满足这个等式。现在我们将这个等式写成 $b = -x_i a + y_i$ 并参考 aob 坐标系，我们将得到对于点 (x_i, y_i) 的唯一直线方程。在 xoy 坐标系中，第 2 个点 (x_j, y_j) 在 aob 坐标系中也有与之对应的直线，且这条直线与 (x_i, y_i) 对应的直线相交于 aob 坐标系中的 (a', b') 点处。这里 a' 是斜率， b' 是 xoy 坐标系上包含点 (x_i, y_i) 和 (x_j, y_j) 的直线的截

距，他们将在 aob 坐标系与一点相交，当该点相交的直线越多，说明原图像是直线的可能性就越大。




图 3.8 (a) xoy 坐标系, (b) aob 坐标系

Hough 变换的基本思想就如图 3.8 表示的那样，定义一个从图像空间到参数空间的一对多的映射关系^[51]。图 3.8(a)可以表示图像中的一簇直线，图 3.8(b)表示直线通过点——线之间的对偶关系，这些直线将相交于一点，确定了该点在 aob 坐标系中的位置就可以知道图像中直线的参数。由此可知，Hough 变换把在图像空间中的直线检测问题转换到参数空间里对点的检测问题，并通过在参数空间里进行的累加统计，最后通过投票检测是图像中的直线。所以从实质上来说，Hough 变换是一种投票机制，通过对参数空间中的离散点进行投票，筛选出想要的结果，这种方法可以有效消除部分噪声的影响，也可以应对直线出现间断的情况。

3.2.1.2 线性回归

在很多农业图像的研究中，Hough变换因为其受噪声影响小和高鲁棒性在国内外的研究中被广泛使用，但是Hough变换的缺点非常明显，计算量大，耗时多，难以满足实时处理的要求，但是当作物行出现缺失时尤其是大面积缺失时往往会产生较大的偏差。线性回归由于其的稳定性和实时性得到了越来越多的运用^{[52][53][54]}。

假设有一系列坐标点 (x_i, y_i) ，有这些坐标点拟合后的直线为 L ，则 L 的方程为：

$$y = kx + b \quad 3-(18)$$

其中 b 为斜距， k 为斜率，则点 (x_i, y_i) 到直线的距离 d 为：

$$d = \frac{|kx + b - y|}{\sqrt{1 + k^2}} \quad 3-(19)$$

所有的点到直线距离的平方和 D 为:

$$D = \sum_{i=1}^N \left[\frac{y_i - (b + kx_i)}{\sqrt{1 + k^2}} \right]^2 \quad 3-(20)$$

其中 N 为作物点的数量。如果点 (x_i, y_i) 在直线上, 则 d 为0, 但不可能所有特征点都恰好落在直线上。线性回归通过计算使所有点到直线的距离的平方和 D 最小, 由此计算得到的直线 L 可以使所有点基本分布在距离直线 L 两侧附近。

为了求 k 和 b 使 D 取最小值, 对式 3-(21)的分子的 k 和 b 分别求偏导并令其为0,

$$\begin{cases} \frac{\partial D}{\partial b} = -2 \sum_{i=1}^N (y_i - b - kx_i) = 0 \\ \frac{\partial D}{\partial k} = -2 \sum_{i=1}^N [y_i - (b + kx_i)]x_i = 0 \end{cases} \quad 3-(21)$$

化解式 3-(21), 最终可以求出 \hat{b} 和 \hat{k} 为

$$\hat{b} = \frac{\sum x_i^2 \sum y_i - \sum x_i y_i}{N(\sum x_i^2) - (\sum x_i)^2} \quad 3-(22)$$

$$\hat{k} = \frac{N(\sum x_i y_i) - \sum x_i^2 \sum y_i}{N(\sum x_i^2) - (\sum x_i)^2} \quad 3-(23)$$

再将 \hat{b} 和 \hat{k} 带入式 3-(18), 就可以得到线性回归的结果方程。




图 3.9 线性回归示意图

3.2.2 基于横条法加线性回归组合算法

在对比 Hough 变换和线性回归的优缺点后,本实验决定使用横条法和线性回归的方法计算作物行。

在确定ROI的位置后,通过横条法得到位置标志点,位置标志点的提取过程如图3.10所示。首先将ROI分成若干横条,横条数量有图片大小决定。然后从左到右,从上到下依次遍历每个横条,用表示一水平横条第*i*列白色像素出现的次数,通过式3-(24)计算得出。

$$s(i) = \sum_{y=i*h}^{y=(i+1)*h} \sum_{x=0}^{x=w} f(x, y) \quad 3-(24)$$

其中*w*为分割后横条的宽, *h*为分割后图像的高。

$$\begin{cases} f(x, y) = 1 & \text{if } point(x, y) = 255 \\ f(x, y) = 0 & \text{if } point(x, y) = 0 \end{cases} \quad 3-(25)$$

其中, *point(x,y)*为图像在该坐标的灰度值。为了求位置标志点,我们采用下面方法:

算法3.1 位置标志点提取算法

1. 计算阈值 μ , $\mu = \frac{1}{N} \sum_{i=0}^{i=w} s(i)$, $N = w * h$

2. 遍历每一横条

(1)当 $s(i) \leq \mu$ & $s(i+1) > \mu$, 说明进入作物行, 记录该点坐标(x_L, y_L);

(2)当 $s(i) > \mu$ & $s(i+1) \leq \mu$, 说明离开作物行, 记录该点坐标(x_R, y_R);

(3)每当完成一轮进入和离开后, 记录该区域的位置标志点(x, y)的坐标并计算区域长度*L*, $x = (x_L + x_R) / 2$, $y = (y_L + y_R) / 2$, $L = x_R - x_L$;

(4)定义一个阈值*d*, 当*L*大于时, 认为目标为作物行, 保存坐标值并取中点为特征点; 否则, 忽略该值继续遍历。

3.若所有水平横条都判断过, 遍历结束; 否则继续遍历下一个水平横条。




图 3.10 位置标志点提取过程

当位置标志点已知后，再使用线性回归就可以得出作物行，导航直线取两条作物行的中线即可。在进行线性回归前，需要将每个位置标志点进行分类，由于自动 ROI 创建策略，这时基本上 ROI 里只包含两条作物行，所以在计算作物行时，判断位置标志点属于哪一条作物行就非常简单，只需要判断该点的横坐标值，如果该位置标志点的横坐标值小于图像宽度的一半，则认为属于左侧的作物行，否则认为该点属于右边的作物行。

3.2.3 实验结果与分析

由于充足的准备工作（自动 ROI 和杂草识别），最后的作物行识别过程通过先使用横条法获得位置标志点，再使用线性回归得到作物行就可以得到准确的结果，图 3.11 展示了通过第二章和第三章所述的方法最后得到的实验结果，实验结果表明，本算法可以高效准确的提取作物行。




图 3.11 作物行检测结果

Hough 变换是直线检测时普遍使用同时有效的方法，因此我们将本文的方法和随机 Hough 变换进行对比，并通过准确度和耗时两个指标对这两种方法的优劣进行衡量，随机 Hough 变换是对 Hough 变换的改进，通过选取随机点代替了 Hough 变换的投票方式，所以计算量大幅减少^[55]。为了评价两种方法的准确度和效率，我们通过测量，人工作出作物行直线，再通过两条直线的夹角大小衡量结果的误差。误差计算过程如图 3.12 所示，图 3.12 中交叉的红线和蓝线一条表示实验结果，另一条表示人为做出的作物行直线。




图 3.12 检测精度示意图

其中 k_1 和 k_2 是 l_1 和 l_2 的斜率， b_1 和 b_2 是在 y 轴的截距。 θ 是 l_1 和 l_2 较小的一个夹角， θ 的大小用于评价准确度， θ 越小，说明结果越精确， θ 的值可以通过式3-(26)求出[56]。

$$\theta = \arctan\left(\frac{|k_1 - k_2|}{|1 + k_1 * k_2|}\right) \tag{3-26}$$

随机Hough变换和线性回归的对比如表3.3所示，表3.3中的数值均为多次测试后计算的平均数值。从表3.3中可以看出，无论是在准确度还是在耗时上，横条法加线性回归的组合算法均优于随机Hough变换，并且当图像逐渐变大时，随机Hough变换的计算量增大趋势也快于组合算法。

表3.3 随机Hough变换和线性回归准确性和耗时的对比

| 图像分辨率(pixels) | 随机 Hough | | 线性回归+横条法 | |
|-----------------|----------|--------|----------|--------|
| | 准确度(°) | 耗时(ms) | 准确度(°) | 耗时(ms) |
| 0—300×200 | 2.21 | 11.1 | 1.66 | 3.3 |
| 300×200—500×300 | 6.36 | 16.6 | 1.16 | 5.3 |
| 500×300—600×400 | 8.35 | 25.5 | 2.61 | 8.5 |

3.3 本章小结

本章介绍了人工神经网络、SVM 和随机森林三种机器学习方法，并使用这三种方法进行杂草识别，因为训练和实验样本均为二值图像，不能使用和颜色相关的特征，所以本文引入了特征点的概念，然后以图像中的连通区域为基本单位，以其轮廓特征和特征点的统计学特征作为特征值进行训练和识别，经过对比实验发现，随机森林的识别效果最好，因此选择了随机森林作为我们的分割器；随后

进行作物行提取，本文分别使用了横条法加线性回归的组合算法和随机 Hough 变换两种方法进行作物行提取并对结果进行了对比，实验结果表明无论是在准确度还是耗时上，横条法加线性回归的组合算法都比随机 Hough 变换更加优秀。

第四章 自动导航系统的设计与实现

4.1 硬件系统的设计与实现

农业视觉导航系统一般由图像采集装置、传感器、计算机和移动平台四部分组成，图像采集装置一般是摄像机，负责采集图像信息，采集的图像通过传感器将图像信息传给计算机，利用计算机强大的计算能力进行图像处理，根据图像处理的结果决定当前行动指令并发送给移动平台使其行进相关操作，从而完成农业作物任务。

本课题设计与开发农业导航系统主要也有这四部分构成，其主要任务是实现图像采集和并根据采集的图像完成导航路径的提取，最终实现自动导航。为此本课题进行了硬件系统的搭建和软件系统的设计。

4.1.1 硬件系统的搭建

本课题所选择的移动平台是韩伯电子技术研究所研发的 HBE-ROBOCAR 车型机器人，可以通过马达驱动来控制设备移动，通过设备内的控制设备（MCU）采集当前车型机器人的状态进行各种控制，如图 4.1 所示。




图 4.1 HBR-RoboCAR 车型机器人

HBE-ROBOCAR 车型机器人采用的是处理器 ATmega128L 模块，该模块使用高性能低功耗的 AVR 8bit 的微控制器，非易失性的程序和数据存储器，JTAG 接口。电机驱动使用 L298P 驱动，电机采用 RB-35GM 型号。传感器包括超声波传感器（AW-120A01 series），距离传感器（GP2Y0A21YK），加速传感器

(ADXL335E)，红外传感器（ST-8L，EL-8L），完全可以反正实验的要求。详细规格参数如表 4.1 所示。

表 4.1 HBE-ROBOCAR 车型机器人规格

| 名称 | 规格 |
|----------------------|---|
| ATmega128L | 8-bit AVR, Microcontroller with 128K Bytes, main control |
| ATmega8L | 8-bit AVR, Microcontroller with 1K Bytes, Voltmeter control |
| L298P | Up to 4A DC Motor Driver 2EA |
| Pan/Tilt | Digital Packet communication |
| RF communication | 2.4G-2.5G selected frequency |
| Camera | VGA CMOS image sensor 30fps |
| USB, RS232 | USB Full Speed, RS232(9600-115200bps) |
| Image format | Motion JPEG 20fps at 160*120 |
| Ultrasonic sensor | 40.0±0.5KHz Frequency, 2.0 KHz Bandwidth, 2EA |
| Accelerometer sensor | 3-Axis Accelerometer sensor 1EA |
| PSD sensor | Distance Measuring Sensors 1EA, 10-80cm |
| Phototransistors | 8-groups Infrared rays sensor |
| Motors | DC geared motor 2EA, DC geared encoder motor 2EA |
| Buzzer | 5V input Buzzer 1EA |
| LED | 10mm high brightness LED, White 2EA, RED 2EA |
| 7-Segment | Voltmeter Display,3-Digit 1EA |
| Regulator | +11.1V VC input, DC output: +5V, +3.3V |
| Battery | +11.1V, 5200mA Lithium Ion 1EA |
| Charge & Adapter | +12.6V 1.2A Battery Charger 1EA |

在图像采集时，由于作业对象和作业环境的不同，为了采集符合要求的图像，要求摄像头的高度、角度方便调节，且调节后摄像头依然要保持稳定。考虑到以上因素，摄像头最终同样选择了韩伯电子技术研究所的产品，所选摄像头通过 HBE-ROBOCAR 车型机器人上的卡槽固定和通过无线信号连接。组装后效果如图 4.2 所示，图 4.2 中 1、2 区域是两个独立旋转模块构成，1 模块可实现前方竖直方向摄像头 0~180°内调节，2 模块可实现水平方向 360°旋转，所以理论上可以

实现无死角拍摄，当 HBE-ROBOCAR 车型机器人通电后，1、2 模块的齿轮将固定，这时摄像头只能通过计算机进行控制，保证了摄像头的稳定性。




图 4.2 组装上摄像头的 HBR-RoboCAR 车型机器人

韩伯电子技术研究所同时提供了相应的传输设备与驱动用于该车型机器人与计算机的信息交互，如图 4.3 所示，这个设备称作 Station，带有 USB 接口，通过设定的波段频率进行连接。




图 4.3 远程接受模块 Station

计算机相当整个导航系统的大脑，负责信息的汇总、处理以及发送，实验中采用个人电脑，具体配置如图 4.4 所示。

查看有关计算机的基本信息



图 4.4 计算机配置参数

4.1.2 摄像机的标定

目前几乎所有的摄像机不能完全满足线性摄像机模型，这是因为制作过程中必定或多或少存在误差，这直接导致了摄像机拍摄出来的图片与理想情况拍摄的图片并不是完全对应的关系。而且大部分摄像机为了提高成像速度，都采用弯曲的镜面，以便在最短的时间里能够收敛足够的光线，俗称的“球面”透镜，这就导致透镜和成像仪难以平行，于是就会存在畸变^[57]，主要有三方面的畸变，分别是径向畸变，切向畸变和薄棱镜畸变^[58]。

径向畸变：径向畸变是由曲面透镜造成的，如果透镜为平面，则径向畸变为 0。曲面导致成像点偏离原来的位置，透镜正中心径向畸变为 0，越远离正中心径向畸变越大，且畸变程度关于正中心对称。径向畸变主要分为枕形畸变和桶形畸变两种 (如图 4.5)，而标定的主要目的就是为了解除径向畸变。




图 4.5 摄像机径向畸变类型

用 x_x 和 y_y 分别表示在水平方向和垂直方向径向畸变大小，如式 4-(1)所示：

$$\begin{cases} x_x = k_1(x^2 + y^2) \\ y_y = k_2(x^2 + y^2) \end{cases} \quad 4-(1)$$

其中 x_x 、 y_y 为矫正后的坐标， k_1 、 k_2 为径向畸变系数， x 、 y 为原始坐标。

切向畸变：由于工艺水平限制，制作的透镜本身与图像平面不平行会导致切向畸变，畸变大小可用式 4-(2)表示：

$$\begin{cases} x_x = x + [2p_1y + p_2(r^2 + 2x^2)] \\ y_y = y + [2p_2y + p_1(r^2 + 2y^2)] \end{cases} \quad 4-(2)$$

其中 r 为点 (x, y) 到主光轴的距离， p_1 、 p_2 为切向畸变系数。

薄棱镜畸变：主要是由于透镜在设计和制造时无法避免的缺陷或误差造成（比如镜头与摄像机像面之间有很小的倾角），可以用下式表示：

$$\begin{cases} x_x = s_1(x^2 + y^2) \\ y_y = s_2(x^2 + y^2) \end{cases} \quad 4-(3)$$

其中 s_1 、 s_2 为非线性畸变系数。

由式 4-(1)、式 4-(2)、式 4-(3)可得摄像机非线性畸变用数学表达式如下：

$$\begin{cases} x_x = k_1x(x^2 + y^2) + x + [2p_1y + p_2(r^2 + 2x^2)] + s_1(x^2 + y^2) \\ y_y = k_2y(x^2 + y^2) + y + [2p_2y + p_1(r^2 + 2y^2)] + s_2(x^2 + y^2) \end{cases} \quad 4-(4)$$

其中 k_1 、 k_2 、 p_1 、 p_2 、 s_1 和 s_2 统称为非线性畸变系数。

本文采用非线性模型对摄像头进行标定，但是如果采用式 4-(4)对摄像头进行标定，可能会出现标定结果不稳定，标定精度低的问题^[59]，经过综合考虑，本文使用基于 OpenCV 的标定方法。

摄像机标定一般使用动态标定和静态标定两种方法，静态方法利用一个参数

已知的模板，使用摄像头对其进行拍摄，由于模板的各种参数已知，便可以通过图像坐标系与空间坐标系之间的对应关系求出摄像机的相关参数；动态标定依靠摄像机在移动状态下拍摄的环境图像间对应关系进行摄像机标定。静态标定标定精度高，但过程比较繁琐，动态标定恰好相反，动态标定过程简单，但标定精度相对较低。综合考虑，本文最终采用 OpenCV 静态标记法。

OpenCV 是一个由 c 和 c++语言编写的跨平台开源视觉计算机视觉库函数，实现了图像处理方面发很多算法，也提供了相应的标定接口，主要使用到的接口有 `cvLoadImage`，用于读取待标定图像，`cvFindChessboardCorners`，用于提取全部角点，`cvFindCornerSubPix` 用于提取亚像素角点位置，`cvDrawChessboardCorners` 提取标定板的角点并记录坐标。标定过程只需要读取待标定图像，接口可以自动提取角点完成标定。OpenCV 提供的接口同时考虑了径向畸变和切向畸变，导致运算量变大，但也使得校正后的结果更加准确，具体实现流程如下。

- 1.设置角点数目为 11×11 。
- 2.读入图像并提取全部角点。
- 3.如果图像处理结束，计算摄像机内外参数并输出结果；否则，返回步骤 2。



图 4.6 角点提取流程

标定实验中每次标定的图片数量大于等于 4 张，在每组实验在拍摄的图像中随机选取 4 张，分别进行 9 组实验，实验结果如表 4.2 所示：

表 4.2 平面方格标定结果

| 焦距 | 成像原点 | 畸变系数 |
|-----------------|-----------------|--------------------------------------|
| [863.72;891.86] | [333.22;256.68] | [-0.4781; 0.4021;-0.0010;-0.0010; 0] |
| [907.90;914.13] | [337.66;251.39] | [-0.7858; 0.8314;-0.0003;-0.0494; 0] |
| [903.75;918.45] | [334.87;247.98] | [-0.5345; 0.6538;-0.0015;-0.0052; 0] |
| [894.28;900.34] | [333.91;246.55] | [-0.6589; 0.7785;-0.0008;-0.0048; 0] |
| [865.52;889.35] | [328.57;251.45] | [-0.6245; 0.5237;-0.0042;-0.0053; 0] |
| [890.58;910.77] | [325.55;249.31] | [-0.5233; 0.3360;-0.0056;-0.0276; 0] |

4.2 软件系统的设计与实现

4.2.1 开发环境和工具

Windows 系列操作系统因其简单的图像化操作界面有很大的普及率，尤其是在中国深受喜爱，其中最新的 Windows 7 系统依然保持着该系列一直以来的稳定性。良好的兼容性好、能够很好的支持硬件使得 Windows 7 成为各种开发环境的首选，本研究选取 Windows 7 作为开发平台。

Visual Studio 是微软公司推出的开发环境，是目前最流行的 Windows 平台应用程序开发环境。Visual Studio 2010 版本于 2010 年 4 月 12 日上市，其集成开发环境（IDE）的界面被重新设计和组织，变得更加简单明了。Visual Studio 2010 同时带来了 NET Framework 4.0、Microsoft Visual Studio 2010 CTP(Community Technology Preview--CTP)，并且支持开发面向 Windows 7 的应用程序，与 Windows 7 具有良好的兼容性。因此，本研究选取 Visual Studio 2010 进行 MFC 开发。

4.2.2 软件的开发与设计

整个导航系统需要完成实时视频采集，视频的保存传输，图像的读取、显示等基本功能功能；需要对采集图像进行灰度化、二值化等预处理工作；需要实现 ROI 自动调整，特征点提取和作物行检测等操作。本研究中视频图像采集及存储由 HBE-ROBOCAR 型号机器人自带模块完成。使用 OpenCV 和 HBE-ROBOCAR

所提供的接口在 Visual Studio 2010 环境下进行 MFC 开发，实现图像读取显示任务、图像预处理、作物行识别等功能。因此，我们将这个视觉导航系统分为三大模块，分别是控制模块，图像预处理模块，导航线提取模块。其中，图像预处理模块又包括图像分割和自动 ROI 两部分，导航线提取又包括杂草识别和作物行识别两部分。

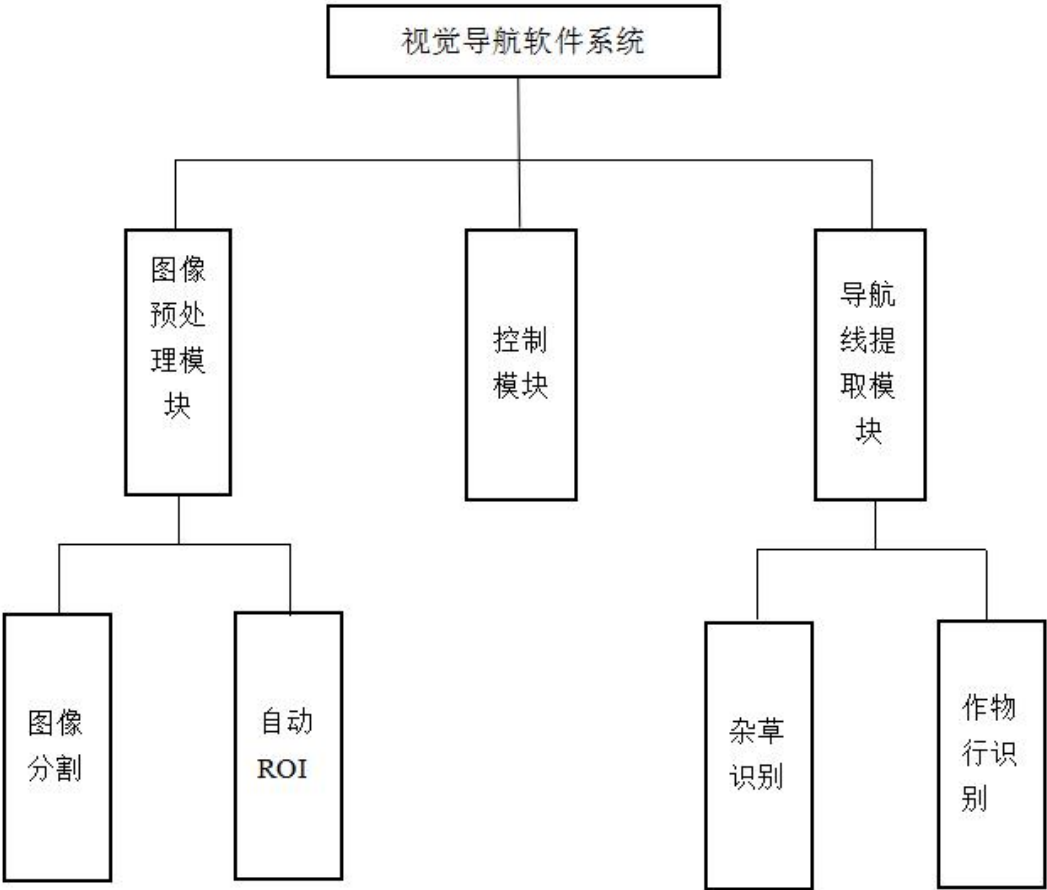


图 4.7 导航软件系统

软件系统的界面设计如图 4.8 所示，图 4.8 用红色矩形分为了 4 个区域，分别对应该软件的 4 个功能。

区域 1 有 Start 和 Stop 两个按钮，分别对应的功能是自动导航的开始和停止。图像分割模块，自动 ROI 生成模块，杂草识别模块和中心线提取模块都集成在其中，其中图像分割和杂草识别训练过程均在 matlab 中完成，这里直接使用训练的结果参数进行判断与识别。

区域 2 是摄像头控制区，这里可以实现是否显示目前拍摄的图像，以及对摄像头角度的控制，从这里调节摄像头每次移动 1°，是为了方便需找最好的拍摄

角度。

区域 3 是移动平台的手动控制区域，可以为系统提供手动操作功能。

区域 4 是输出区，用于保存系统的操作记录，同时显示实时拍摄内容。



图 4.8 主界面

4.3 仿真实验与结果分析

为了测试导航系统的准确性和稳定性，我们设计了模拟实验，模拟实验地点选择在校内的试验田里，实验前采集作物与杂草并进行人工摆放用于模拟实际场景。具体模拟方法为，一共模拟 4 条作物行，作物行宽度为 5-10cm 之间，作物行与作物行直接间距为 20-23cm 并保持平行。作物行模拟完毕后，想作物行范围内随机撒树叶，用于模拟杂草。

当天天气阴有小雨，光线较暗，模拟实验如图 4.9 所示。通过手动控制将移动平台移动到作物行前，点击开始按钮，移动平台开始自动导航程序开启。实验中实测移动平台以 0.65m/s 的速度前进，实验总时长为 1 分 17 秒。在实验中，每过几秒，我们就将提取的导航路径偏转角度记录下来，并绘制成折线图如图 4.10 所示，并以 JPG 格式保存在电脑中，结果如图 4.11 所示。



图 4.9 模拟实验过程




图 4.10 模拟实验结果




图 4.11 模拟实验结果随机截取图

4.4 本章小结

本章主要介绍了农业导航系统的组成部分，并从软件和硬件两个角度介绍了整个导航系统所使用到的相关技术基础。其中硬件主要包括图像采集装置、移动平台和计算机等，并分析了摄像机畸变产生的原因及类型，介绍了摄像机的标定原理，使用 OpenCV 标定法进行标定实验，并介绍了这种标定方法的特点、原理以及实验过程；软件主要任务包括图像的读取和显示、图像预处理、杂草识别、特征点提取和作物行的识别。设计了模拟实验，对模拟实验的设计和结果进行了介绍。

第五章 结论与展望

5.1 结论

农业机器人已经成为现代智能农业机械一个重要研究方向，在自动喷洒农药和施肥、收割、除草、病虫害检测等方面有着广泛的应用。相对于 GPS 导航，机器视觉效率高成本低，得到了广泛的推广。本文主要以机器视觉技术为基础，配合移动平台和图像采集装置，实现农业自动导航系统。在硬件方面，采用的是韩伯电子技术研究所研制的 HBE-ROBOCAR 型号机器人和相关配套设备为基础；图像处理方面，首先通过层级分割结构进行图像分割，识别出作物部分，然后设计了自动 ROI 的创建算法，再通过随机森林识别出杂草并删除，再通过横条法和线性回归提取出导航线，最后根据导航线结果给移动平台下行动指令。通过统计实验结果和对比得出以下结论与结果：

(1)为了克服其他方法对户外复杂情况的弱适应性，本文使用了基于局部特征的层级分割结构进行分割，并通过基于离散-连续的梯度方向估计进行优化，从而保证在不牺牲准确度的基础上提高处理速度。该方法的核心思想是使用一个离散-连续的学习方法对各种情况的图片的局部中级区域描述符进行学习，从而可以预测各种情况的图片的每一个像素点的局部梯度，再方向分水岭分割和贪婪合并法得到分割结果。通过与超绿法和模糊聚类两种分割方法的对比实验发现，该方法可以在各种天气条件和生长情况下准确分割出作物，具有鲁棒性和准确性的优势。

(2)在实验中我们发现，导航路径往往是由移动平台两侧的作物行决定的，所以正如许多学者所做的一样，可以通过创建合理的 ROI 提高导航的准确度和效率。但目前的 ROI 的创建往往是通过人工计算得到的，不具有普遍性，针对这种现状，本文提出自动 ROI 的思想。通过实验总结出 ROI 创建原则，设计并实现自动 ROI 算法。经过实验结果发现，该算法可以创建准确的 ROI 区域，保证在 ROI 中只存在我们需要的两条作物行，从而有助于提高杂草识别和作物行识别的准确度。

(3)为了克服杂草对导航精度的影响，本文通过机器学习进行杂草识别，选择了三种常见的分类器进行学习，分别是人工神经网络、SVM 和随机森林。由于

我们的训练和识别目标为二值图像，无法使用颜色、纹理等相关特征，因此引入了特征点的概念。我们以图像中的连通区域为基本单位，以其轮廓特征和特征点的统计学特征作为特征值进行训练和识别，包括周长、面积、密度、特征点的最大值、特征点的最小值、特征点的均值、特征点的比值等。实验结果表明当选择随机森林作为分类器时识别效果最好，作物的识别率为 93.8%，杂草的识别率为 91.1%。

(4)介绍了 Hough 变换和线性回归作物行提取算法，由于选取了合适的 ROI，简化了位置标记点的分类，本体提出使用使得横条法加线性回归的组合算法将自身的优势最大化，实验结果也表明采用线性回归的方法具有拟合精度高，鲁棒性强，实时性好的优点，因此最后采用横条法加线性回归的组合算法作为作物行提取算法。

(5)文章详细介绍了如何搭建导航系统，韩伯电子技术研究所 HBE-ROBOCAR 型号机器人为移动平台，设计并开发了机器人控制系统，并通过计算机控制实现图像的采集、处理和系统的控制，展示了所使用到的技术设备和控制系统。讨论了摄像机产生的畸变的原因及三种畸变类型，然后介绍了摄像机的标定原理和方法，并使用 OpenCV 标定法进行了标定实验。搭建了基于机器视觉的农业导航系统。最后在校内开展了模拟实验，从郊区采集作物和杂草模拟环境，实验总时长为 1 分 17 秒，机器人 0.65m/s 的速度前进，移动期间最大偏转角度不超过 6° ，平均偏转角度为 2° 至 3° 之间。

5.2 展望

目前虽然在图像处理和移动平台的控制上取得了一些成果，但是由于作者知识的局限性和时间的限制，许多地方仍然需要改进，对后续工作做如下展望：

1. 在使用层次结构进行分割的时候，由于时间和场地的限制，没有拍摄到在各种情况下更多的图片，最后收集了 105 图片用于训练和测试，总体数量偏少，后续工作可以继续收集更多在各种情况下的图片进行训练。
2. 目前自动 ROI 的参数为经过大量试验后得到的固定值，当图片大小发生变化时仍然使用同样的参数显然并不合适，所以接下来需要研究得到可以随图片大小变化而变化的参数。

3. 在杂草识别过程中，目前只有 10 个特征值作为训练输入，后续工作中考虑加入更多的特征值，用于提高杂草识别的成功率。
4. 优化软件系统，目前软件系统比较简单，仅包括自动导航和人工操作两大基本功能，后续应该进一步优化系统，包括界面和布局优化，加入更多功能，包括将训练过程集成到系统，参数的调整等，以及系统的整体优化，提高系统的相应速度。

参考文献

- [1] 金衡模, 高焕文, 王晓燕. 农业机械自动化的现状与推进模式[J]. 中国农业大学学报, 2000, 5(2): 44-49
- [2] 姬长英. 农业生产过程智能化的发展与展望[J]. 农业机械学报, 1999, 30(1): 106-110
- [3] 袁佐云. 基于计算机视觉的作物行中心线识别研究[D]. 中国农业大学, 2005.
- [4] Hague T, Marchant J A, Tillett N D. Ground based sensing systems for autonomous agricultural vehicles [J]. Computers and Electronics in Agriculture, 2000, 25(1): 11-28
- [5] Wilson J N. Guidance of agricultural vehicles—a historical perspective [J]. Computers and electronics in agriculture, 2000, 25(1): 3-9
- [6] 钟玉琢. 机器人视觉技术[M]. 北京: 国防工业出版社, 1994, 60-90.
- [7] Reid J F, Searcy S W. An algorithm for computer vision sensing of a row crop guidance directrix [J]. SAE Transactions, 1991, 100(2): 93-105.
- [8] Fontaine V, Crowe T G. Development of line-detection algorithms for local positioning in densely seeded crops[J]. Canadian Biosystems Engineering, 2006, 48: 719-729
- [9] Gerrish J B, Fehr B W, Van-Ee G R, et al. Self-steering tractor guided by computer vision[J]. Applied Engineering in Agriculture, 1997, 13(5): 559-563
- [10] Lee W S, Slaughter D C, Giles D K. Robotic weed control system for tomatoes[J]. Precision Agriculture, 1999, 1(1): 95-113
- [11] Slaughter D C, Chen P, Curley R G. Vision guided precision cultivation[J]. Precision Agriculture, 1999, 1(2): 199-216
- [12] Bjorn Astrand, Albert-Jan Baevreldt. An Agricultural Mobile Robot with Vision-Based Perception For Mechanical Weed Control[J]. Autonomous Robots, 2002, 13: 21-35
- [13] Søgaard H T, Olsen H J. Determination of crop rows by image analysis without segmentation [J]. Computers and Electronics in Agriculture, 2003, 38: 141-158
- [14] Kise M, Zhang Q, Mas F R. Stereovision-based 3D field recognition for agricultural automatic guidance tractor[C]. CIGR International Conference, 2004
- [15] Kise M, Zhang Q, Mas F R. A stereovision-based crop row detection method for tractor-automated guidance[J]. Biosystems Engineering, 2005, 90(4): 357-367
- [16] Hannan M W, Burks T F, Bulanon D M. 2007. Areal-time machine vision algorithm for robotic

citrus harvesting[A].St.Joseph,Mich.:ASAE,2007,ASAE Paper No.073125

[17] Bakker T, Wouters H, Van Asselt K, et al. A vision based row detection system for sugar beet[J]. Computers and Electronics in Agriculture, 2008, 60(1): 87-95.

[18] Romeo J, Pajares G, Montalvo M, et al. Crop row detection in maize fields inspired on the human visual perception[J]. The Scientific World Journal, 2012, 2012.

[19] Guerrero J M, Guijarro M, Montalvo M, et al. Automatic expert system based on images for accuracy crop row detection in maize fields[J]. Expert Systems with Applications, 2013, 40(2): 656-664.

[20] Choi K H, Han S K, Han S H, et al. Morphology-based guidance line extraction for an autonomous weeding robot in paddy fields[J]. Computers and Electronics in Agriculture, 2015, 113: 266-274.

[21] 沈明霞.自主行走农业机器人视觉导航信息处理技术研究 [D]. 南京农业大学, 2001.

[22] 周俊.农用轮式移动机器人视觉导航系统的研究 [D]. 南京: 南京农业大学, 2003.

[23] 冯雷.基于 GPS 和传感技术的农用车辆自动导航系统的研究[D]. 杭州: 浙江大学, 2004.

[24] 张方明, 应意斌. 田间路径识别算法和基于立体视觉的车辆自动导航方法研究 [D]. 杭州: 浙江大学生物系统工程与食品科学学院, 2006.

[25] 赵颖. 农业自主行走机器人视觉导航技术的研究[D]. 北京: 中国农业大学, 2006.

[26] 赵颖, 孙群, 张民. 农业自主行走机器人视觉导航技术研究[J]. 计算机工程与设计, 2010 (13): 3032-3035.

[27] 胡炼, 罗锡文, 曾山, 等. 基于机器视觉的株间机械除草装置的作物识别与定位方法[J]. 农业工程学报, 2013, 29(10): 12-18.

[28] 孟庆宽, 何洁, 仇瑞承, 等. 基于机器视觉的自然环境下作物行识别与导航线提取[J]. 光学学报, 2014 (7): 172-178.

[29] 张漫, 项明, 魏爽, 季宇寒, 仇瑞承, 孟庆宽. 玉米中耕除草复合导航系统设计与试验[J]. 农业机械学报, 2015, S1: 8-14.

[30] Woebbecke D M, Meyer G E, Von Bargen K, et al. Shape features for identifying young weeds using image analysis[J]. Transactions of the ASAE, 1995, 38(1): 271-281.

[31] Donoser M, Schmalstieg D. Discrete-continuous gradient orientation estimation for faster image segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 3158-3165.

- [32] Ren Z, Shakhnarovich G. Image segmentation by cascaded region agglomeration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 2011-2018.
- [33] Taylor C. Towards fast and accurate segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 1916-1922.
- [34] Arbelaez P, Maire M, Fowlkes C, et al. Contour detection and hierarchical image segmentation[J]. Pattern Analysis and Machine Intelligence, IEEE Transactions on, 2011, 33(5): 898-916.
- [35] Winder S A J, Brown M. Learning local image descriptors[C]//Computer Vision and Pattern Recognition, 2007. CVPR'07. IEEE Conference on. IEEE, 2007: 1-8.
- [36] Lim J J, Dollar P, Zitnick III C L. Learned mid-level representation for contour and object detection: U.S. Patent Application 13/794,857[P]. 2013-3-12.
- [37] Criminisi A, Shotton J, Konukoglu E. Decision forests: A unified framework for classification, regression, density estimation, manifold learning and semi-supervised learning[J]. Foundations and Trends® in Computer Graphics and Vision, 2012, 7(2–3): 81-227.
- [38] Maire M, Arbeláez P, Fowlkes C, et al. Using contours to detect and localize junctions in natural images[C]//Computer Vision and Pattern Recognition, 2008. CVPR 2008. IEEE Conference on. IEEE, 2008: 1-8.
- [39] Dollár P. Piotr's image and video Matlab toolbox[J]. Retrieved December, 2012, 14: 2012.
- [40] Remlinger K. Introduction and application of random forest on high throughput screening data from drug discovery[C]//Proc. of the Workshop for the SAMSI Program on Data Mining and Machine Learning. 2003.
- [41] Tom M Mitchell.机器学习[M].曾华军,张银奎译.北京:机械工业出版社,2003.
- [42] Breiman L. Random forests[J]. Machine learning, 2001, 45(1): 5-32.
- [43] Remlinger K. Introduction and application of random forest on high throughput screening data from drug discovery[C]//Proc. of the Workshop for the SAMSI Program on Data Mining and Machine Learning. 2003.
- [44] 米切尔, 华军, 机械学, 等. 机器学习[M]. 机械工业出版社, 2003.
- [45] 萨, 逸飞. 模式识别: 原理, 方法及应用[M]. 清华大学出版社, 2002.
- [46] Du J X, Wang X F, Zhang G J. Leaf shape based plant species recognition[J]. Applied

mathematics and computation, 2007, 185(2): 883-893.

[47] Hemming J, Rath T. PA—Precision Agriculture: Computer-Vision-based Weed Identification under Field Conditions using Controlled Lighting[J]. Journal of agricultural engineering research, 2001, 78(3): 233-243.

[48] Haug, S., Michaels, A., Biber, P., & Ostermann, J. (2014, March). Plant classification system for crop/weed discrimination without segmentation. In Applications of Computer Vision (WACV), 2014 IEEE Winter Conference on (pp. 1142-1149). IEEE.

[49] Hough P V C. Method and means for recognizing complex patterns[R]. 1962.

[50] Duda R O, Hart P E. Use of the Hough transformation to detect lines and curves in pictures [J]. Communications of the ACM, 1972, 15(1): 11-15.

[51] Nguyen T T, Pham X D, Jeon J W. An improvement of the Standard Hough Transform to detect line segments[C]//Industrial Technology, 2008. ICIT 2008. IEEE International Conference on. IEEE, 2008: 1-6.

[52] Billingsley J, Schoenfisch M. The successful development of a vision guidance system for agriculture [J]. Computers and electronics in agriculture, 1997, 16(2): 147-163.

[53] Montalvo M, Pajares G, Guerrero J M, et al. Automatic detection of crop rows in maize fields with high weeds pressure [J]. Expert Systems with Applications, 2012, 39(15): 11889-11897.

[54] Ribeiro A, Fernández-Quintanilla C, Barroso J, et al. Development of an image analysis system for estimation of weed pressure[C]//Precision agriculture'05. Papers presented at the 5th European Conference on Precision Agriculture, Uppsala, Sweden. Wageningen Academic Publishers, 2005: 169-174.

[55] Ji R, Qi L. Crop-row detection algorithm based on Random Hough Transformation[J]. Mathematical and Computer Modelling, 2011, 54(3): 1016-1020.

[56] Jiang G, Wang Z, Liu H. Automatic detection of crop rows based on multi-ROIs[J]. Expert Systems with Applications, 2015, 42(5): 2429-2441.

[57] 行麦玲.大视场短焦距物镜 CCD 摄像系统畸变测量技术研究.[D].北京:北京理工大学.2003

[58] 金海龙. 插秧机视觉导航关键技术的研究[D].浙江理工大学,2015.

[59] Tsai, Roger Y. Efficient and Accurate Camera Calibration Technique for 3D Machine Vision[C]. IEEE Computer Society Conference on Computer Vision and Pattern Recognition,

1986: 364-347.

攻读学位期间的研究成果

[1]汪博,桂江生,周建平,葛忠明. 基于最小二乘法的早期玉米作物行检测研究[J]. 浙江理工大学学报,2015,07:547-551.

[2]一种农作物行的识别方法及装置 、[CN105046229A](#). 中国发明专利

致谢

时光荏苒，研究生生活马上就要结束了，回顾过去，从刚入学到现在的分分秒秒，精彩的一幕幕依然历历在目。我的每一分成就，都离不开身边的人对我的帮助，此时此刻，我想对所有关心和帮助过我的人表达深深的谢意。

首先感谢我的导师桂江生副教授。桂老师渊博的学术知识、严谨的治学态度和宽以待人严以律己的生活作风都深深地影响了我。桂老师不但教会了我怎么做学问，而且教会了我怎么做人，两年半的研究生学习让我培养了学术思想，能够独立的发现问题、分析问题和解决问题。无论在学习上、工作上还是生活上，桂老师都对我给予无私的关怀，再次感谢您的教育与培养。

感谢已经毕业的师姐郝丽，刚步入研究生时对于研究方向一无所知，而你对我知无不言，言无不尽，无论我提出多么幼稚的问题，都耐心的为我讲解。你勤奋的学习态度和扎实的学术功底都给我树立了良好的榜样。

感谢实验室同级的张青同学。感谢实验室的全体人员。在此，还要感谢我那些好朋友们对我毫不吝啬的帮助，是你们的存在让我的生活更加的充满意义，谢谢你们。

最后感谢关爱我的父母，是你们给了我无私的支持与关怀，多年来你们一直都在为我付出，以后我一定好好回报你们。

再次感谢所有关心帮助我的亲人、老师和朋友，祝福你们!